Federated Learning における Adaptive Model Poisoning Attack と Robust Aggregation の評価に関する実験報告書

3CDA2216 笠原秀星

2026 年 9 月 1 日

1 研究背景・概要

Federated Learning（以下, FL）は, 生データを共有することなく複数のデバイスや組織が協調して機械学習モデルを学習する分散学習の枠組みである [1]. FL は, ユーザのプライバシー保護と機械学習の両立を可能にする技術として注目されており, スマートフォンにおける単語予測や顔認識, 音声認識技術の向上に利用されている. また, 厳格なプライバシー規制によりデータ共有が困難な医療分野や, 自動運転車におけるリアルタイムデータの活用など, 幅広い分野への応用が期待されている [2].

一方で, FL には収束性, データ分布の不均一性（Non-I.I.D.）, 通信コスト, 大規模環境への適用, モデル集約手法など, さまざまな課題が存在する [3]. 特に, FL では多数の参加者が学習に関与するため, 悪意のあるクライアントによる攻撃への耐性を確保することが重要な研究課題となっている. 医療データや個人情報などの機密性の高いデータを扱う応用が想定されることから, 安全かつ信頼性の高い学習環境の実現が求められている.

FL に対する代表的な攻撃として Poisoning Attack が挙げられる. Poisoning Attack は大きく Data Poisoning Attack と Model Poisoning Attack の 2 種類に分類される. Data Poisoning Attack は学習データそのものを改ざんする攻撃であり, ラベル反転攻撃や Backdoor Attack などが含まれる. 一方, Model Poisoning Attack はクライアントがサーバへ送信するモデル更新や勾配情報を改ざんする攻撃であり, 勾配操作や最適化手法を利用した攻撃などが提案されている.

これらの攻撃に対する防御手法としては, 異常検知, Robust Aggregation, 摂動機構の 3 つに大別される. 異常検知にはコサイン類似度やクラスタリング, スコアベース手法などが用いられる. また, Robust Aggregation には Krum, Trimmed Mean, Median, Bulyan などの集約手法が提案されている. さらに, 摂動機構としては差分プライバシーを利用した手法が広く研究されている [4].

本研究では, これらの中でも Model Poisoning Attack に着目する. Data Poisoning Attack に関してはこれまで多くの研究が行われており, 攻撃に対してロバストな集約手法や検知手法が多数提案されている. 一方で, Model Poisoning Attack は学習データではなくモデル更新そのものを改ざんするため, サーバ側から攻撃を識別することが困難であり, より深刻な脅威となる. また, その防御手法に関する研究は Data Poisoning Attack と比較して十分に進んでいるとは言えない.

さらに, Fang らは Adaptive Model Poisoning Attack を提案し, 既存の Robust Aggregation 手法を考慮した攻撃によって防御機構を回避できる可能性を示している [5]. このことは, 従来の防御手法が必ずしも十分な耐性を有していないことを示唆しており, Adaptive Model Poisoning Attack に対する詳細な評価が必要である.

そこで本研究では, IID 環境および Non-IID 環境において Adaptive Model Poisoning Attack が FL の学習性能に与える影響を評価する. また, Krum や Trimmed Mean などの Robust Aggregation 手法に対する攻撃の有効性を比較・分析し, 既存防御手法の限界を明らかにする. さらに, 攻撃が成立する要因について考察するとともに, Model Poisoning Attack に対する効果的な防御手法について検討することを目的とする.

2 事前知識

2.1 Federated Learning

先に述べたように Federated Learning は生データを共有することなく複数のデバイスや組織が協調して機械学習モデルを学習する分散学習の枠組みである [1]. 集約アルゴリズムとして Federated Averaging (以下,FedAvg) を用いる.FedAvg は Google が 2016 年に発表した論文の中で示されたものである [6].

2.1.1 FedAvg

アルゴリズム 1 に FedAvg の処理手順を示す。

まず，サーバはグローバルモデル w_0 を初期化する。その後，各通信ラウンド t において，全クライアント数 K のうち割合 C に応じた m 個のクライアントをラン

表 1　FedAvg で用いる主な記号

記号	意味
K	全クライアント数
C	各ラウンドで参加する割合
S_t	ラウンド t で選択されたクライアント集合
w_t	グローバルモデル
w_{t+1}^k	クライアント k が更新したモデル
n_k	クライアント k のデータ数
E	ローカル学習のエポック数
B	ミニバッチサイズ
η	学習率

Algorithm 1 Federated Averaging (FedAvg)

Server executes:
Initialize w_0
for each round $t = 1, 2, \ldots$ **do**
  $m \leftarrow \max(C \cdot K, 1)$
  $S_t \leftarrow$ random set of m clients
  for all $k \in S_t$ in parallel **do**
    $w_{t+1}^k \leftarrow \text{ClientUpdate}(k, w_t)$
  end for
  $w_{t+1} \leftarrow \sum_{k \in S_t} \frac{n_k}{n_t} w_{t+1}^k$
end for

ClientUpdate(k, w)
Split P_k into batches of size B
for $i = 1$ to E **do**
  for batch $b \in B$ **do**
    $w \leftarrow w - \eta \nabla \ell(w; b)$
  end for
end for
return w to server

ダムに選択する。選択されたクライアント集合を S_t とする。

選択された各クライアントは，サーバから受け取ったグローバルモデル w_t を用いてローカル学習を実施する。各クライアントは自身が保有するデータ集合 P_k をミニバッチサイズ B ごとに分割し，エポック数 E 回の学習を行う。モデル更新には確率的勾配降下法（SGD）を用い，学習率を η とすると，各ミニバッチ b に対して次式によりパラメータを更新する。

$$w \leftarrow w - \eta \nabla \ell(w; b) \tag{1}$$

ここで，$\ell(w; b)$ はミニバッチ b に対する損失関数であり，$\nabla \ell(w; b)$ はその勾配を表す。

ローカル学習終了後，各クライアントは更新後のモデル w_{t+1}^k をサーバへ送信する。サーバは受信したモデルを，各クライアントの保有データ数 n_k に応じて重み付け平均することで新たなグローバルモデル w_{t+1} を生成する。

$$w_{t+1} = \sum_{k \in S_t} \frac{n_k}{n_t} w_{t+1}^k \tag{2}$$

ただし，

$$n_t = \sum_{k \in S_t} n_k \tag{3}$$

である。この処理を複数ラウンド繰り返すことで，生データを共有することなくグローバルモデルを学習する。

2.2 Data Poisoning Attack

Data Poisoning Attack は，攻撃者が学習データそのものを改ざんし，グローバルモデルの性能低下や誤動作を引き起こす攻撃である。Federated Learning では，各クライアントが保有するローカルデータや学習過程をサーバが直接確認できないため，悪意のあるクライアントが改ざんしたデータを用いて学習を行うことで，モデルに悪影響を与えることが可能である [4]。

Data Poisoning Attack は，Label Flipping Attack，Poisoning Sample Attack，Backdoor Attack などに分類される。Label Flipping Attack は，学習データのラベルを意図的に別のラベルへ変更する攻撃である。例えば，数字認識タスクにおいて「1」のラベルを「7」に変更して学習させることで，モデルの分類性能を低下させることができる。

Poisoning Sample Attack は，学習データそのものを改ざんする攻撃であり，ノイズの付加や特定のパターンの埋め込みなどによって学習結果を操作する。

一方，Backdoor Attack は，特定のトリガを含む入力に対してのみ誤分類を引き起こす攻撃である。攻撃者はトリガ付きデータを学習データへ混入させることで，通常の入力に対する性能を維持したまま，トリガを含む入力に対してのみ攻撃者が指定したラベルを出力するようモデルを誘導する。そのため，Backdoor Attack は高い攻撃成功率とステルス性を有しており，発見が困難であるという特徴を持つ。

Data Poisoning Attack は実装が比較的容易である一方，異常なデータ分布やラベルの偏りを利用した検知手法によって防御できる場合がある。そのため近年では，学習データではなくモデル更新そのものを改ざんする

Model Poisoning Attack に関する研究が盛んに行われている [4][7][8]。

2.3 Model Poisoning Attack

Model Poisoning Attack は，悪意のあるクライアントがサーバへ送信するモデル更新や勾配情報を改ざんし，グローバルモデルの性能低下や誤動作を引き起こす攻撃である。Data Poisoning Attack が学習データそのものを改ざんするのに対し，Model Poisoning Attack は学習後のモデルパラメータを直接操作する点に特徴がある。そのため，サーバ側から攻撃の有無を判断することが困難であり，Federated Learning における深刻な脅威の一つとして注目されている [4]。

Model Poisoning Attack は, Gradient Manipulation, Optimization Methods，Untargeted Attack の 3 種類に分類される [4]。Gradient Manipulation は，モデル更新の勾配を意図的に操作する攻撃であり，勾配反転（Sign Flipping Attack）やランダムな勾配の挿入などが代表例として知られている。これらの攻撃は，グローバルモデルの収束を妨害し，性能を低下させることを目的とする。

Optimization Methods は，攻撃効果を最大化するようにモデル更新を最適化する攻撃である。攻撃者は正常なモデル更新との差を小さく保ちながら，攻撃目的を達成するようにモデルを改ざんすることで，異常検知や防御機構による検出を回避する。Backdoor Attack や Model Replacement Attack の多くはこの分類に含まれる。

Untargeted Attack は，特定の入力に対する誤分類ではなく，グローバルモデル全体の性能低下を目的とする攻撃である。攻撃者はモデル更新を大きく改ざんすることで，学習の収束を妨害し，モデルの可用性を低下させる。

2.4 Robust Aggregation

Robust Aggregation は，悪意のあるクライアントによる異常なモデル更新の影響を軽減することを目的とした集約手法である [4]。従来の FedAvg では，各クライアントから送信されたモデル更新を重み付き平均によって集約するため，悪意のあるクライアントが極端なモデル更新を送信した場合，グローバルモデルが大きな影響を受ける可能性がある。

この問題に対処するため，Byzantine Fault Tolerance の考え方を取り入れた Robust Aggregation が提案されている。代表的な手法として Mean（FedAvg), Median, Trimmed Mean，Krum，Bulyan などが知られており，異常なモデル更新を除外または影響を低減しながらグローバルモデルを更新する。

2.4.1 Mean (FedAvg)

FedAvg は，Federated Learning において最も広く利用されている集約手法である。各クライアントから送信されたモデル更新を，保有するデータ数に応じて重み付け平均することで新たなグローバルモデルを生成する。

FedAvg は実装が容易で計算コストも低いという利点を持つ一方，異常なモデル更新の影響を受けやすいという欠点がある。そのため，Model Poisoning Attack に対して脆弱であることが知られている。

2.4.2 Median

Median は，各パラメータについて中央値を採用する集約手法である。平均値ではなく中央値を利用することで, 極端に大きな値や小さな値の影響を受けにくくなる。

そのため，悪意のあるクライアントが異常なモデル更新を送信した場合でも，その影響を軽減できる。しかし，多数のクライアントが攻撃に参加している場合には性能が低下する可能性がある。

2.4.3 Trimmed Mean

Trimmed Mean は，各パラメータについて極端に大きい値と小さい値を一定数除外した後に平均を計算する手法である。

この手法は外れ値の影響を低減できるため，単純な平均よりも Model Poisoning Attack に対してロバストである。一方で，正常なクライアントの更新が除外される場合もあり，学習性能が低下する可能性がある。

2.4.4 Krum

Krum は，各クライアントのモデル更新と他のクライアントとの距離を計算し，最も多くのクライアントと類似しているモデル更新を選択する手法である。

平均を取るのではなく，信頼できると判断された単一のモデル更新を採用するため，異常なモデル更新を排除しやすいという特徴を持つ。しかし，クライアント数が増加すると計算コストが大きくなるという課題がある。

2.4.5 Bulyan

Bulyan は，Krum と Trimmed Mean を組み合わせた集約手法である。まず Krum を用いて信頼できるモデル更新を選択し，その後 Trimmed Mean によって集約を行う。

複数の Byzantine 攻撃に対して高い耐性を持つことが報告されているが，計算コストが大きく，クライアント数が多い環境では実行時間が増加するという欠点がある。

本研究では，FedAvg を基準手法とし，Median, Trimmed Mean，Krum および Bulyan を Robust Ag-

gregation として採用する。また，Adaptive Model Poisoning Attack を適用した場合の攻撃成功率やモデル精度の変化を比較し，各集約手法の有効性を評価する。

3 関連研究

Subhash Sagar らは, Federated Learning における Poisoning Attack および防御手法に関する包括的なサーベイを行っている。彼らは攻撃を Data Poisoning Attack と Model Poisoning Attack に分類し，さらに防御手法についても Robust Aggregation や異常検知手法などの観点から体系的に整理している。また，各攻撃手法および防御手法の特徴や課題を比較し，Federated Learning におけるセキュリティ研究の方向性を示している [4].

Minghong Fang らは，Byzantine-robust Federated Learning に対する Local Model Poisoning Attack を提案した。従来の Data Poisoning Attack とは異なり，攻撃者は学習データではなく悪意あるクライアントのモデル更新そのものを操作する。攻撃を最適化問題として定式化することで，Krum，Bulyan，Median，Trimmed Mean といった Byzantine-robust Aggregation 手法に対しても有効な攻撃を実現し，既存の防御手法が十分ではないことを示した [5].

Chulin Xie らは，DBA (Distributed Backdoor Attacks) を提案した。従来の Backdoor Attack では全ての攻撃者が同一のトリガを学習するのに対し，DBA ではグローバルトリガを複数のローカルトリガへ分割し，各悪意あるクライアントへ分散して埋め込む。この手法により，従来手法と比較して高い攻撃成功率とステルス性を実現できることを示した [7].

Eugene Bagdasaryan らは，Model Replacement Attack を提案した。この攻撃では，攻撃者が生成した悪意あるモデル更新を拡大して送信することで，集約後のグローバルモデルへ Backdoor を埋め込むことが可能となる。また，Federated Learning で用いられる Secure Aggregation 環境では各クライアントの更新内容を詳細に観測できないため，異常検知による防御が困難であることを示した [9].

Tuan D. Nguyen らは，Backdoor Attack に対する防御手法である FLAME を提案した。FLAME はモデルクラスタリングによる異常なモデル更新の検出，重みクリッピングによる影響の抑制，およびノイズ付与を組み合わせることで，正常なモデル性能を維持しながら Backdoor の影響を低減できることを示した [8].

これらの研究では，Poisoning Attack および Backdoor Attack の有効性や防御手法について検討されている。しかし，Adaptive Model Poisoning Attack に対する各種 Robust Aggregation 手法の耐性については十分な比較評価が行われていない。そこで本研究では，Median，Trimmed Mean，Krum，Bulyan などの Robust Aggregation 手法を対象として Adaptive Model Poisoning Attack を適用し，IID 環境および Non-IID 環境における防御性能を評価する。

4 実験方法

4.1 実験概要

本研究では，Federated Learning 環境において Adaptive Model Poisoning Attack を実施し，各種 Robust Aggregation 手法の耐性を評価する．

実験では，全 100 クライアントから構成される Federated Learning 環境を構築し，悪性クライアント割合およびデータ分布を変化させながら学習を行う．

また，FedAvg，Median，Trimmed Mean，Krum，Bulyan の 5 種類の集約手法を対象とし，攻撃下におけるモデル性能の変化を比較する．

4.2 データセット

本研究では，画像分類タスクの代表的なデータセットである MNIST を用いる．MNIST は手書き数字画像から構成される 10 クラス分類データセットであり，訓練データ 60,000 件，テストデータ 10,000 件を含む．

データ分布が攻撃および防御性能に与える影響を評価するため，IID 環境および Non-IID 環境の両方で実験を行う．IID 環境では各データをシャッフルして全クライアントへ均等に分配する．一方，Non-IID 環境では Fang ら [5] の 4.1 節と同じ方式を用いる．すなわち，100 クライアントをラベル数（10）と同数のグループへ均等に分割し，ラベル l の学習データを対応するグループへ確率 $p = 0.5$ で，残りを他の 9 グループへ均等に割り当てることで，グループごとに保有ラベルが偏った不均一なデータ分布を再現する．

4.3 学習モデル

学習モデルには，Fang ら [5] が MNIST 用の “DNN” 分類器として用いた構成（同論文 Table 7a）に合わせた畳み込みニューラルネットワーク（CNN）を用いる．モデル構造は，3×3 の畳み込み層（出力 30 チャネル）と ReLU，2×2 の最大プーリング，3×3 の畳み込み層（出力 50 チャネル）と ReLU，2×2 の最大プーリング，1250 ノードから 200 ノードへの全結合層と ReLU，および 10 クラス分類のための出力層から構成される．

原論文との対応を取るため，本研究でも同一のモデル構造を採用する．

4.4 攻撃設定

攻撃手法には，Fang らが提案した Adaptive Model Poisoning Attack を用いる．

Adaptive Model Poisoning Attack は，従来の Model Poisoning Attack とは異なり，サーバで用いられる集約手法の特性を考慮して悪意あるモデル更新を生成する攻撃である．攻撃者は，グローバルモデルの性能低下を目的としてモデル更新を最適化し，Robust Aggregation による防御を回避しながら攻撃を行う．

正常クライアントと悪性クライアントの定義・選出方法

本研究では，各ラウンドの通信に参加するクライアントを，攻撃に関与しない**正常（honest）クライアント**と，Adaptive Model Poisoning Attack による攻撃済みの更新を送信する**悪性（malicious）クライアント**の 2 種類に分類する．正常クライアントはローカル学習の結果をそのままサーバへ送信するのに対し，悪性クライアントはローカル学習自体は正常クライアントと同様に行うものの，サーバ側で更新が集約される直前に，その更新が攻撃によってクラフトされた値へ差し替えられる．

悪性クライアントの選出は，クライアント総数と悪性クライアント割合から悪性クライアント数を算出した上で，trial 番号を乱数シードとして用いた乱数生成によりクライアント ID の中から重複なく抽出することで行う．本研究では同一条件を trial 番号 1–20 の 20 回繰り返すが，この trial 番号はデータ分割・モデル初期値・悪性クライアントの選出のすべてに連動させる．したがって，trial 番号が同一であれば常に同一の設定が再現される一方，trial 番号を変えると，データ分割やモデル初期値だけでなく，悪性クライアントとして選出されるクライアント ID 自体も変化する．

本研究では，悪性クライアントが正常なローカル学習を実施した後，学習結果をそのまま送信する代わりに，Adaptive Model Poisoning Attack によって生成した悪意あるモデル更新をサーバへ送信する．

full knowledge 攻撃者の実現方法

Fang らの攻撃は，攻撃者がサーバで使用中の集約手法を把握しており，かつ悪性クライアント同士が結託して互いの更新内容を参照できる，いわゆる full knowledge 攻撃者を前提とする．本実験基盤である Flower では，各クライアントは独立したプロセスとして動作し，クライアント同士が直接通信・結託する手段を持たない．そのため，本研究ではこの前提をサーバ側で模倣する形で実現する．

具体的には，各クライアントは通常どおりローカル学習を行い，学習結果をサーバへ送信する．サーバは全クライアントの更新を受信し集約する直前に，送信元のクライアント ID から悪性クライアントに該当する更新を特定した上で，それらを正常クライアントの更新情報とグローバルモデルの情報から生成した攻撃済みの更新へ差し替える．全クライアントの更新が集まるサーバのこのタイミングを，攻撃者が他クライアントの更新を参照して結託する場とみなすことで，クライアントプロセスが独立しているという制約の下でも full knowledge 攻撃者を模擬している．

集約手法別のクラフト方法

Adaptive Model Poisoning Attack では，攻撃者はまず正常クライアントの更新の平均とグローバルモデルとの差からグローバルモデルを押しやる方向（攻撃方向）を求める．その上で，サーバが使用する集約手法に応じて，以下のように悪性クライアントの更新をクラフトする．

- **Median，Trimmed Mean：** 座標ごとに正常クライアントの更新の最大値・最小値を求め，攻撃方向側の最大値・最小値のさらに外側の値を悪性クライアントへ割り当てる境界値攻撃を行う．悪性クライアント間で外側への押し出し具合を段階的にずらすことで，座標ごとの外れ値除外処理によって悪性の更新がまとめて除外されることを防ぐ．
- **Krum，Bulyan：** 悪性クライアント全員を正常クライアントの更新の重心を起点とした攻撃方向上の 1 点に密集させ，Krum によって悪性クライアントの更新が選択される範囲でグローバルモデルから最大限離れるように，攻撃強度を表すパラメータを探索する．Bulyan は Krum による候補選択を繰り返し用いるため，同様のクラフト方法を適用する．
- **FedAvg：** 外れ値を除外する仕組みを持たないため，選択回避のための探索は不要であり，悪性クライアントの更新をグローバルモデルとの差分に対して一定倍率で拡大する Scale Attack を適用する．

なお，本実装は Fang らが示した「集約手法の特性を突いた最適化ベースの攻撃」という中核的な着想を踏襲した独自実装であり，原論文の数式をそのまま再現したものではなく，近似・簡略化した再実装である点に留意されたい．

また，攻撃の影響を評価するため，全 100 クライアント中の悪性クライアント数を 0，10，20，30 と変化させる．これに対応する悪性クライアント割合はそれぞれ 0%，10%，20%，30% である．

さらに，IID 環境および Non-IID 環境の両方において実験を実施し，データ分布の違いが攻撃効果に与える影

響についても評価する．

4.5 防御設定

防御手法として，Robust Aggregation に分類される FedAvg, Median, Trimmed Mean, Krum, Bulyan を用いる．

FedAvg は全クライアントのモデル更新の平均を用いる集約手法である．Median は各パラメータについて中央値を採用する．Trimmed Mean は極端な値を除外した後に平均を計算する．Krum は他のクライアントとの距離に基づいて信頼できるモデル更新を選択する手法である．Bulyan は Krum による候補選択と Trimmed Mean による集約を組み合わせた手法であり，高い Byzantine 耐性を有することが報告されている．これら 5 手法を比較することで，Adaptive Model Poisoning Attack に対する耐性の違いを評価する．

5 評価方法

5.1 評価指標

評価指標には Accuracy および Loss を用いる．

Accuracy はテストデータに対する分類精度を表す指標であり，学習されたグローバルモデルの性能を評価するために用いる．

Loss は損失関数の値を表す指標であり，学習の収束状況を評価するために用いる．Loss が小さいほどモデルの予測結果と正解ラベルとの差が小さく，学習が適切に進行していることを示す．

実験では，各通信ラウンドにおける Accuracy および Loss の推移を記録する．Adaptive Model Poisoning Attack によって Accuracy が低下し，Loss が増加するほど，攻撃の影響が大きいと判断する．

5.2 比較条件

本研究では，

- 集約手法（FedAvg, Median, Trimmed Mean, Krum, Bulyan）
- 悪性クライアント割合（0%，10%，20%，30%）
- データ分布（IID，Non-IID）

を組み合わせて比較を行う．

集約手法・悪性クライアント割合・データ分布の組み合わせは $5 \times 4 \times 2 = 40$ 通りである．ただし，Bulyan の悪性クライアント割合 0.3（$f = 30$）はロバスト性条件 $n \geq 4f + 3$（$100 < 123$）を満たさないため，IID・Non-IID の 2 条件を除外し，実験対象は 38 条件とする．

各条件について，データ分割・モデル初期値・悪性クライアント選出を連動させた trial を 20 回繰り返す．Fang ら [5] は同一条件を 50 trial 繰り返して平均するが，本研究では計算コストの都合で 20 trial とした．したがって，実施する実験の総数は

$$38 \times 20 = 760$$

回である．

6 実験環境

実験は Python を用いて実装する．深層学習フレームワークには PyTorch を使用し，Federated Learning の実装には Flower を用いる．

全クライアント数は 100 とし，各通信ラウンドでは全クライアントが学習へ参加する．

学習設定は，Fang ら [5] の 4.1 節（DNN 分類器）に合わせ，以下のように定めた．

- **ローカルエポック数：** 1（各クライアントは 1 ラウンドあたりミニバッチ勾配降下を 1 エポック分実行する）
- **バッチサイズ：** 32
- **学習率：** 0.001
- **最適化手法：** 素朴な確率的勾配降下法（SGD）
- **通信ラウンド数：** 20

ただし，Fang らは同設定の DNN 分類器を 2,000 iterations 学習させているのに対し，本研究の通信ラウンド数 20 はそれに遠く及ばない．§7.2 で述べるとおり，このラウンド数は攻撃なしのベースラインでも学習が収束しない水準であり，適切なラウンド数の決定は今後の課題である．

7 実験

7.1 実験条件と結果の読み方

本章では，第 4 章で述べた 5 種類の集約手法（FedAvg, Median, Trimmed Mean, Krum, Bulyan），4 通りの悪性クライアント割合（malicious ratio = 0.0，0.1，0.2，0.3），2 通りのデータ分布（IID，Non-IID）を組み合わせた条件で，Adaptive Model Poisoning Attack 下での学習を実施した結果を示す．実験環境は Fang ら [5] の設定に合わせ，モデルは CNN（同論文 Table 7a），最適化は素朴な SGD，バッチサイズ 32，Non-IID はラベル l を対応グループへ確率 $p = 0.5$ で割り当てる Fang 方式である．攻撃は毎ラウンド，サーバ側で full knowledge 攻撃者を模擬して適用する．

集約手法・割合・分布の組み合わせ $5 \times 4 \times 2 = 40$ のうち，Bulyan の malicious ratio 0.3（$f = 30$）はロバスト性条件 $n \geq 4f + 3$（$100 < 123$）を満たさず未実行の

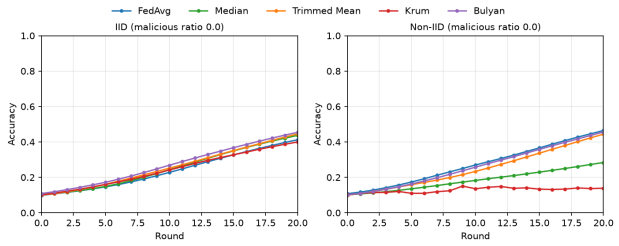


図 1　攻撃なし（malicious ratio 0.0）における各集約手法の Accuracy 推移（20 trial 平均）．すべての曲線が Round 20 でもなお上昇を続けており，学習が収束していない

ため，実験対象は 38 条件である．各条件を，データ分割・モデル初期値・悪性クライアント選出を連動させた trial 番号 1–20 の 20 回繰り返し，合計 760 回の学習を行った．全 760 回が通信ラウンド 20 まで完了している．

各手法の結果は，データ分布ごとに 1 枚の図にまとめて示す．図の横軸は通信ラウンド，縦軸は左パネルが Accuracy，右パネルが Loss であり，malicious ratio ごとに 20 trial の平均を実線，± 標準偏差を淡い帯で表す．図の作成に用いたラウンド別の数値（20 trial 平均 ± 標準偏差）は，付録の各表に掲載する．全 38 条件の最終ラウンド（Round 20）の Accuracy 一覧を表 3 に示す．

7.2　本実験の位置づけと制約

結果の解釈に入る前に，本実験の重大な制約を明示する．**本実験の通信ラウンド数 20 は，学習の収束に対して不足している．**Fang らは同一の学習設定（CNN 分類器）を 2,000 iterations 学習させているのに対し，本実験は 20 ラウンドで打ち切っており，攻撃の有無にかかわらず学習が完了していない．

その根拠を表 2 および図 1 に示す．攻撃なし（malicious ratio 0.0）の条件でも，Round 20 の Accuracy は IID 環境で 0.40–0.45，Non-IID 環境の Krum に至っては 0.14 にとどまる．さらに，Round 16 から 20 にかけても Accuracy は毎ラウンド +0.01–+0.02 の割合で増加し続けており，学習曲線がプラトーに達していない．すなわち，どの条件も「学習途上」で打ち切られている．

表 2　攻撃なし（malicious ratio 0.0）条件における学習の到達度．Round 20 の Accuracy が低く，かつ Round 16–20 の Accuracy がなお毎ラウンド増加し続けていることは，通信ラウンド数 20 が学習の収束に対して不足していることを示す（各条件 20 trial 平均）

	IID		Non-IID	
集約手法	Acc.@20	ΔAcc./round	Acc.@20	ΔAcc./round
FedAvg	0.412	+0.0167	0.464	+0.0193
Median	0.437	+0.0170	0.284	+0.0110
Trimmed Mean	0.445	+0.0186	0.444	+0.0213
Krum	0.400	+0.0143	0.139	+0.0018
Bulyan	0.454	+0.0171	0.456	+0.0195

このため，本章の結果からは以下を**結論できない**．

- 各条件の Accuracy の絶対値．収束後の値とは大きく異なる可能性が高い．
- 「どの集約手法が最も頑健か」という手法間の順位．特に IID 環境では，攻撃による差よりも学習の進み方の差が支配的である．

以下では，収束前という前提のもとで**読み取れる範囲の傾向**のみを述べる．適切な通信ラウンド数の決定と，収束後の再評価は今後の課題であり，著者が現在検証中である．

なお，本実験はモデル構造・Non-IID 生成方式・最適化手法を Fang らに合わせた一方，反復回数（20 対 2,000）と trial 数（20 対 50），および FedAvg 向けの攻撃クラフト（本実験は Scale Attack を用いるが，Fang らは mean 集約を Trimmed Mean 向け攻撃で攻撃する）が原論文と異なる．攻撃アルゴリズムと実験条件の対応関係の詳細は別途整理している．

表 3　各条件における最終ラウンド（Round 20）の Accuracy（各条件 20 trial の平均 ± 標準偏差）．本スイープは通信ラウンド数が不足しており（§7.2），攻撃なし（Ratio 0.0）でも学習が収束していない点に注意

集約手法	Ratio 0.0	Ratio 0.1	Ratio 0.2	Ratio 0.3
IID				
FedAvg	0.412±0.091	0.657±0.046	0.704±0.070	0.765±0.031
Median	0.437±0.107	0.439±0.090	0.398±0.083	0.328±0.088
Trimmed Mean	0.445±0.080	0.413±0.080	0.350±0.081	0.346±0.110
Krum	0.400±0.089	0.359±0.105	0.331±0.083	0.288±0.075
Bulyan	0.454±0.106	0.400±0.116	0.426±0.110	—
Non-IID				
FedAvg	0.464±0.086	0.495±0.131	0.673±0.102	0.693±0.088
Median	0.284±0.098	0.181±0.080	0.096±0.023	0.053±0.032
Trimmed Mean	0.444±0.071	0.187±0.074	0.090±0.026	0.064±0.033
Krum	0.139±0.052	0.036±0.033	0.059±0.039	0.065±0.036
Bulyan	0.456±0.088	0.258±0.077	0.071±0.032	—

Bulyan の Ratio 0.3 はロバスト性条件 $n \geq 4f + 3$ を満たさないため未実行．

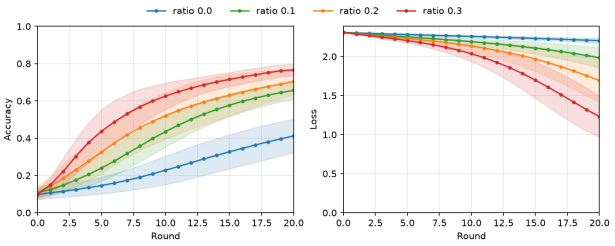


図 2　FedAvg・IID における malicious ratio 別の Round-Accuracy および Round-Loss の推移(20 trial の平均 ± 標準偏差)

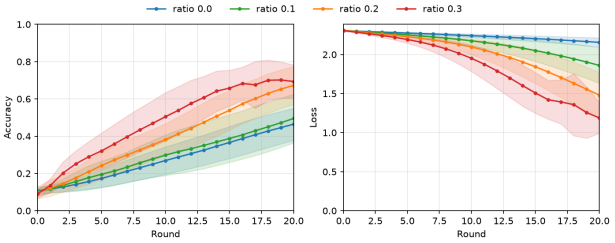


図 3　FedAvg・Non-IID における malicious ratio 別の Round-Accuracy および Round-Loss の推移（20 trial の平均 ± 標準偏差）

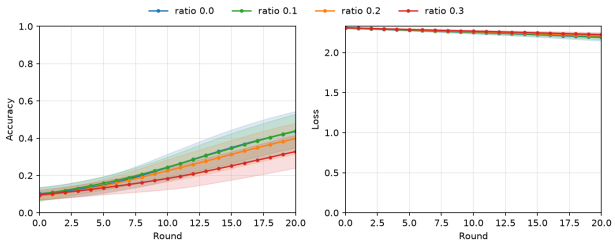


図 4　Median・IID における malicious ratio 別の Round-Accuracy および Round-Loss の推移(20 trial の平均 ± 標準偏差)

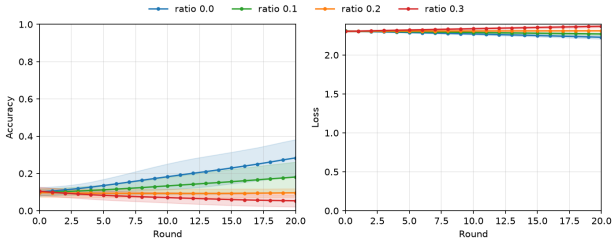


図 5　Median・Non-IID における malicious ratio 別の Round-Accuracy および Round-Loss の推移（20 trial の平均 ± 標準偏差）

7.3　FedAvg

FedAvg の結果を図 2（IID），図 3（Non-IID）に，ラウンド別の数値を付録の表 4，表 5 に示す．

IID・Non-IID のいずれでも，**malicious ratio が高いほど Round 20 の Accuracy が高い**という，直感に反する結果が得られた．IID では ratio 0.0/0.1/0.2/0.3 で 0.41/0.66/0.70/0.77，Non-IID で 0.46/0.50/0.67/0.69 であり，Loss も同様に ratio が高いほど小さい．

これは頑健性の結果ではなく，アーティファクトである．外れ値除去を持たない FedAvg に対して，本実装は悪性クライアントの更新方向を反転させず，honest なローカル学習で得た更新量 $\Delta = \text{local} - \text{global}$ を 10 倍に拡大する Scale Attack を用いる．悪性クライアントも正常な SGD を行うため，拡大された更新は**正しい学習方向を向いたまま大きさだけが 10 倍**になる．平均への寄与が大きくなることで，実効的な更新幅（学習率）が上がるのと同じ効果が生じる．学習率 0.001 の SGD が 20 ラウンドで大きく学習不足である本設定では，この実効学習率の増加がむしろ学習を加速し，Accuracy の上昇として現れたと考えられる．したがってこの挙動は，(1)FedAvg 向けクラフトが Fang らの mean 攻撃ではないこと，(2) 通信ラウンド数が不足していること，の両方に起因する．収束するまで学習した場合に同じ傾向が続く保証はない．

7.4　Median

Median の結果を図 4，図 5 に，数値を付録の表 6，表 7 に示す．

IID 環境では，いずれの malicious ratio でも Round 20 の Accuracy は 0.33–0.44 にとどまり（未収束），ratio の増加に対して単調にわずかに低下する（ratio 0.0 から 0.3 で −0.11）．trial 間の標準偏差は 0.08–0.11 と大きいが，これは主に学習が未収束で trial ごとの進み方に差があるためである．

Non-IID 環境では低下が顕著になる．ratio 0.0 は Round 20 で 0.28 まで上昇を続けるが，ratio 0.1 は 0.18，ratio 0.2，0.3 は Round 5 以降ほぼ chance 水準（0.10 前後）で頭打ちとなり，ratio 0.3 では微減に転じる．ratio 増加に対する低下量は −0.10，−0.19，−0.23 である．

Non-IID 環境かつ高 ratio では，座標ごとの中央値が悪性クライアントの押し出しによって攻撃方向へずれ，学習が立ち上がる前に Accuracy が chance 水準へ張り付いたと考えられる．

7.5　Trimmed Mean

Trimmed Mean の結果を図 6，図 7 に，数値を付録の表 8，表 9 に示す．

IID 環境では Median と同様に，全 ratio が未収束のまま Round 20 で 0.35–0.45 に達し，ratio の増加に対して単調にわずかに低下する．

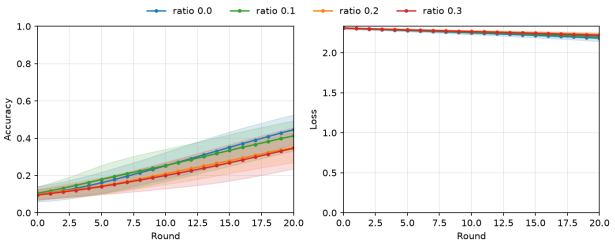


図 6　Trimmed Mean・IID における malicious ratio 別の Round-Accuracy および Round-Loss の推移（20 trial の平均 ± 標準偏差）

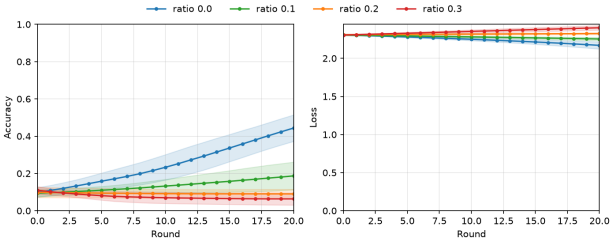


図 7　Trimmed Mean・Non-IID における malicious ratio 別の Round-Accuracy および Round-Loss の推移（20 trial の平均 ± 標準偏差）

Non-IID 環境では Median より落ち込みが急である．ratio 0.0 は Round 20 で 0.44 まで上昇するが，ratio 0.1 で 0.19，ratio 0.2，0.3 では Round 5 以降 chance 水準に張り付く（ratio 増加に対する低下量は −0.26，−0.35，−0.38）．

Non-IID 環境ではクライアントごとに座標分布の形状が異なり，片側で除外する割合（f/n）を上回る悪性クライアントが存在すると，トリム後の平均に除外しきれない悪性値が残るため，Non-IID・高 ratio で学習が chance 水準にとどまったと考えられる．

7.6　Krum

Krum の結果を図 8，図 9 に，数値を付録の表 10，表 11 に示す．

IID 環境では全 ratio が未収束で，Round 20 の Accuracy は ratio 0.0/0.1/0.2/0.3 で 0.40/0.36/0.33/0.29 と，ratio の増加に対して単調に低下する．

Non-IID 環境の悪化が際立つ．**攻撃なし（ratio** 0.0**）ですら Round 20 の Accuracy は** 0.14 で，同条件の他手法（0.28–0.46）を大きく下回る．ratio 0.1–0.3 では chance 水準を下回る 0.04–0.07 まで低下し，Loss は ratio とともに増加する（2.35 から 3.17）．

Krum は毎ラウンド 1 クライアントの更新のみを採用するため，Non-IID 環境では選択されるクライアントのローカルデータ分布が偏っており，20 ラウンドでは有効な更新が積み上がらない．攻撃の有無を問わず 5 手法中

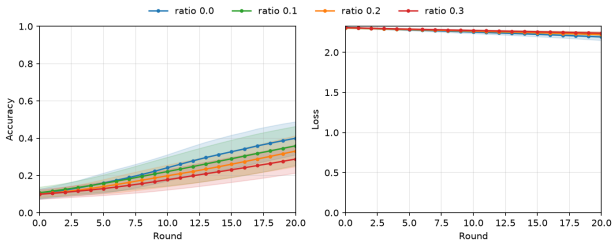


図 8　Krum・IID における malicious ratio 別の Round-Accuracy および Round-Loss の推移（20 trial の平均 ± 標準偏差）

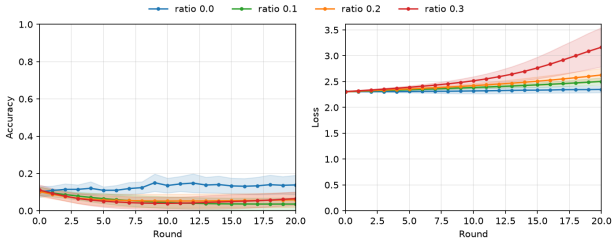


図 9　Krum・Non-IID における malicious ratio 別の Round-Accuracy および Round-Loss の推移（20 trial の平均 ± 標準偏差）

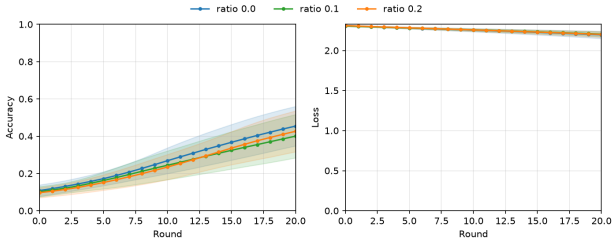


図 10　Bulyan・IID における malicious ratio 別の Round-Accuracy および Round-Loss の推移（20 trial の平均 ± 標準偏差，malicious ratio 0.3 は未実行）

で最も低い Accuracy を示す点は，「Krum が最も脆弱」という Fang らの指摘と整合する．

7.7　Bulyan

Bulyan の結果を図 10，図 11 に，数値を付録の表 12，表 13 に示す．malicious ratio 0.3 はロバスト性条件を満たさず未実行である．

IID 環境では，ratio 0.0/0.1/0.2 で Round 20 の Accuracy が 0.45/0.40/0.43 と未収束ながら概ね同水準を保つ．

Non-IID 環境では，ratio 0.0 の 0.46 に対し，ratio 0.1 で 0.26，ratio 0.2 で 0.07 と急激に低下し，ratio 0.1 から 0.2 の間で chance 水準へ落ち込む．

Bulyan は Krum による候補選択と Trimmed Mean による座標集約を組み合わせるため，IID 環境では Krum 単体より高い Accuracy を示し，Non-IID 環境でも ratio

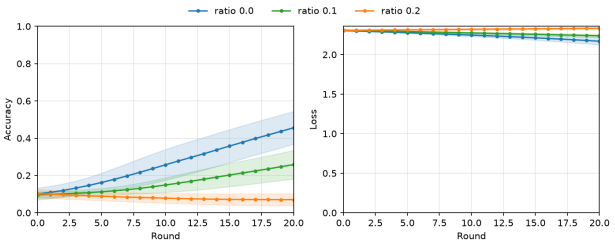


図 11　Bulyan・Non-IID における malicious ratio 別の Round-Accuracy および Round-Loss の推移（20 trial の平均 ± 標準偏差，malicious ratio 0.3 は未実行）

0.1 までは Krum・Non-IID を上回る．ただし ratio 0.2 では他の頑健集約と同様に chance 水準へ落ち込む．

7.8　現時点で読み取れる範囲のまとめ

表 3 および各節の結果から，§7.2 で述べた「収束前」という制約付きで，以下の傾向が読み取れる．

- **悪性クライアント割合の影響：** FedAvg を除く 4 手法で，malicious ratio の増加に伴い Round 20 の Accuracy が単調に低下する．Non-IID 環境では Median・Trimmed Mean・Bulyan が ratio 0.2 以上で chance 水準（0.10 前後）へ張り付く．FedAvg のみ ratio 増加で Accuracy が上昇したが，これは §7.3 で述べたアーティファクトである．
- **データ分布の影響：** すべての頑健集約で Non-IID 環境の Accuracy が IID 環境を大きく下回る．特に Krum は Non-IID 環境では ratio 0.0 の時点で学習がほとんど立ち上がらない．
- **手法間の比較：** 学習が未収束のため確定的な順位付けは保留するが，Krum が全条件で最も低い Accuracy を示す点は Fang らの主張と整合する．

これらはいずれも，通信ラウンド数を Fang 並みに増やしてベースラインを収束させた上で再検証する必要がある．

8　全体的な結論と考察

本研究では，MNIST を用いた Federated Learning 環境において，FedAvg，Median，Trimmed Mean，Krum，Bulyan の 5 種類の集約手法に対し Adaptive Model Poisoning Attack を適用し，IID 環境および Non-IID 環境における耐性の評価を試みた．実験条件は Fang ら [5] に合わせ，モデル構造（CNN，同論文 Table 7a），Non-IID の生成方式（同 4.1 節），最適化手法（素朴な SGD），悪性クライアント割合（0/10/20/30%）を原論文に対応させた．

ただし第 7.2 項で述べたとおり，本実験の通信ラウンド数 20 は Fang らの 2,000 iterations に遠く及ばず，攻撃なしのベースラインですら Accuracy が IID 環境で 0.4 前後，Krum・Non-IID 環境で 0.14 と収束していない．そのため，以下の結論は収束前の予備的観察に基づく暫定的なものである．

その制約の下で得られた傾向は次のとおりである．

- **悪性クライアント割合：** FedAvg を除く 4 手法で，割合の増加に伴い最終 Accuracy が単調に低下した．Non-IID 環境では Median・Trimmed Mean・Bulyan が割合 0.2 以上で chance 水準に張り付いた．FedAvg のみ割合の増加で Accuracy が上昇したが，これは FedAvg 向けクラフトが Fang らの mean 攻撃（Trimmed Mean 向け攻撃の転用）ではなく Scale Attack であり，正しい方向の更新を 10 倍に拡大することが，学習不足の SGD の実効学習率を上げるアーティファクトによる．
- **データ分布：** すべての頑健集約で Non-IID 環境が IID 環境より大きく悪化した．Krum は Non-IID 環境では割合 0.0 から学習がほとんど立ち上がらない．
- **手法間：** 学習が未収束のため順位は確定しないが，Krum が全条件で最も低い Accuracy を示し，「Krum が最も弱い」という Fang らの指摘と整合する．

Fang らが論文「Local Model Poisoning Attacks to Byzantine-Robust Federated Learning」で指摘している

1. 攻撃者が増えるほど精度が悪化する点
2. Non-IID 環境は IID 環境に比べ精度が悪化する点
3. 手法の中で Krum が最も弱い点

のうち，(2) と (3) は本予備実験でも一貫して観測された．(1) は FedAvg を除く 4 手法で観測されたが，FedAvg では上記アーティファクトにより逆の結果となった．

今後の課題として，第一に，通信ラウンド数を Fang 並み（2,000 iterations 相当）に増やし，攻撃なしのベースラインを収束させた上での再評価が必要である．適切なラウンド数は現在検証中である．第二に，trial 数を Fang らの 50 に近づけ，試行間のばらつきを縮小する必要がある．第三に，本実装は Fang らの中核的な着想を踏襲した近似・簡略化した再実装であり，Krum／Bulyan 向けクラフトの基準点（受信グローバルモデルか，honest 更新の重心か）や FedAvg 向け攻撃の選び方など，原論文の数式との差分が残る．これらの対応関係の精査と，攻撃が防御を回避する機構（更新ベクトルの距離構造など）の定量的な分析を今後の課題とする．

参考文献

[1] Priyanka Mary Mammen, “Federated Learning: Opportunities and Challenges,” Proceedings of ACM Conference, 2021.

[2] Tian Li, Anit Kumar Sahu, Ameet Talwalkar, Virginia Smith, “Federated Learning: Challenges, Methods, and Future Directions,” arXiv preprint arXiv:1908.07873, 2019.

[3] Chuan Ma, Jun Li, Ming Ding, Howard H. Yang, Feng Shu, Tony Q. S. Quek, H. Vincent Poor, “On Safeguarding Privacy and Security in the Framework of Federated Learning,” arXiv preprint arXiv:1909.06512, 2020.

[4] Subhash Sagar, Chang-Tsun Li, Seng W. Loke, Jinho Choi, “Poisoning Attacks and Defenses in Federated Learning: A Survey,” IEEE Security & Privacy, 2023.

[5] Minghong Fang, Xiaoyu Cao, Jinyuan Jia, Neil Zhenqiang Gong, “Local Model Poisoning Attacks to Byzantine-Robust Federated Learning,” Proceedings of the 29th USENIX Security Symposium (USENIX Security 2020), pp. 1605–1622, 2020.

[6] H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, Blaise Aguera y Arcas, “Communication-Efficient Learning of Deep Networks from Decentralized Data,” Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS), pp. 1273–1282, 2017.

[7] Chulin Xie, Keli Huang, Pin-Yu Chen, Bo Li, “DBA: Distributed Backdoor Attacks against Federated Learning,” International Conference on Learning Representations (ICLR), 2020.

[8] Tuan D. Nguyen et al., “FLAME: Taming Backdoors in Federated Learning,” 31st USENIX Security Symposium (USENIX Security 2022), pp. 1415–1432, 2022.

[9] Eugene Bagdasaryan, Andreas Veit, Yiqing Hua, Deborah Estrin, Vitaly Shmatikov, “How To Backdoor Federated Learning,” Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics (AISTATS), pp. 2938–2948, 2020.

9 付録

本節では，第 7 章の各図の作成に用いたラウンド別の Accuracy および Loss の数値を，集約手法・データ分布ごとに示す．いずれの表も各条件 20 trial の平均 ± 標準偏差であり，元データは `feature/windows_experiments` ブランチの `experiments/_logs/results.csv` である．§7.2 で述べたとおり，本スイープは通信ラウンド数が学習の収束に対して不足している点に注意されたい．

表 4　FedAvg・IID における malicious ratio 別の Round-Accuracy と Round-Loss（各条件 20 trial の平均 ± 標準偏差）

	Ratio 0.0		Ratio 0.1		Ratio 0.2		Ratio 0.3	
Round	Acc.	Loss	Acc.	Loss	Acc.	Loss	Acc.	Loss
0	0.099±0.026	2.308±0.008	0.108±0.026	2.309±0.010	0.107±0.037	2.305±0.005	0.101±0.024	2.311±0.006
1	0.107±0.029	2.302±0.007	0.124±0.030	2.297±0.010	0.141±0.052	2.289±0.008	0.149±0.036	2.288±0.008
2	0.115±0.032	2.297±0.008	0.147±0.037	2.285±0.012	0.185±0.072	2.275±0.013	0.220±0.073	2.268±0.013
3	0.124±0.035	2.292±0.008	0.176±0.051	2.273±0.014	0.231±0.090	2.260±0.018	0.303±0.092	2.247±0.019
4	0.135±0.040	2.287±0.009	0.206±0.062	2.262±0.017	0.278±0.104	2.246±0.023	0.378±0.107	2.227±0.025
5	0.146±0.045	2.282±0.010	0.240±0.070	2.251±0.020	0.326±0.113	2.231±0.029	0.437±0.116	2.204±0.032
6	0.159±0.050	2.277±0.011	0.277±0.077	2.240±0.023	0.373±0.117	2.215±0.036	0.487±0.113	2.179±0.041
7	0.174±0.056	2.272±0.012	0.318±0.082	2.228±0.027	0.417±0.121	2.198±0.043	0.531±0.105	2.150±0.052
8	0.191±0.063	2.267±0.013	0.358±0.084	2.216±0.031	0.456±0.123	2.179±0.051	0.568±0.095	2.118±0.065
9	0.209±0.070	2.262±0.014	0.398±0.085	2.203±0.035	0.490±0.124	2.158±0.061	0.600±0.082	2.080±0.081
10	0.228±0.077	2.257±0.015	0.435±0.083	2.190±0.040	0.521±0.125	2.134±0.072	0.626±0.070	2.036±0.100
11	0.248±0.082	2.253±0.016	0.470±0.078	2.175±0.046	0.548±0.125	2.108±0.086	0.649±0.060	1.984±0.123
12	0.268±0.085	2.247±0.017	0.501±0.074	2.160±0.052	0.573±0.123	2.079±0.101	0.669±0.052	1.925±0.148
13	0.289±0.088	2.242±0.019	0.529±0.068	2.144±0.059	0.594±0.120	2.046±0.118	0.686±0.045	1.857±0.175
14	0.308±0.090	2.237±0.020	0.554±0.064	2.126±0.067	0.613±0.117	2.008±0.137	0.702±0.041	1.781±0.204
15	0.327±0.091	2.232±0.022	0.577±0.061	2.107±0.075	0.630±0.111	1.967±0.159	0.715±0.038	1.697±0.230
16	0.345±0.092	2.226±0.023	0.598±0.058	2.086±0.085	0.647±0.103	1.921±0.182	0.728±0.037	1.607±0.253
17	0.363±0.094	2.221±0.025	0.615±0.055	2.064±0.095	0.663±0.094	1.870±0.207	0.740±0.035	1.512±0.269
18	0.380±0.093	2.215±0.027	0.631±0.052	2.039±0.106	0.677±0.086	1.814±0.233	0.752±0.034	1.416±0.277
19	0.397±0.092	2.209±0.029	0.645±0.049	2.013±0.117	0.691±0.078	1.755±0.258	0.761±0.032	1.320±0.276
20	0.412±0.091	2.203±0.030	0.657±0.046	1.985±0.130	0.704±0.070	1.692±0.283	0.765±0.031	1.230±0.261

表 5　FedAvg・Non-IID における malicious ratio 別の Round-Accuracy と Round-Loss（各条件 20 trial の平均 ± 標準偏差）

	Ratio 0.0		Ratio 0.1		Ratio 0.2		Ratio 0.3	
Round	Acc.	Loss	Acc.	Loss	Acc.	Loss	Acc.	Loss
0	0.107±0.019	2.305±0.007	0.102±0.022	2.309±0.008	0.099±0.034	2.310±0.006	0.091±0.022	2.307±0.005
1	0.117±0.021	2.299±0.008	0.116±0.020	2.297±0.009	0.121±0.043	2.293±0.007	0.135±0.037	2.287±0.009
2	0.128±0.025	2.293±0.008	0.136±0.036	2.286±0.012	0.146±0.046	2.278±0.012	0.202±0.061	2.266±0.016
3	0.141±0.032	2.287±0.009	0.157±0.052	2.275±0.015	0.176±0.054	2.262±0.017	0.252±0.070	2.244±0.024
4	0.156±0.040	2.281±0.011	0.177±0.064	2.264±0.019	0.209±0.065	2.246±0.024	0.289±0.082	2.220±0.034
5	0.173±0.048	2.275±0.012	0.196±0.071	2.252±0.024	0.242±0.074	2.228±0.031	0.321±0.096	2.193±0.047
6	0.192±0.055	2.269±0.014	0.213±0.076	2.239±0.030	0.272±0.078	2.209±0.040	0.358±0.105	2.160±0.064
7	0.212±0.061	2.262±0.016	0.234±0.081	2.225±0.037	0.300±0.081	2.186±0.051	0.397±0.112	2.121±0.085
8	0.231±0.066	2.256±0.018	0.257±0.091	2.210±0.045	0.327±0.081	2.160±0.064	0.434±0.117	2.074±0.110
9	0.250±0.070	2.249±0.020	0.278±0.099	2.194±0.054	0.354±0.083	2.131±0.080	0.469±0.123	2.018±0.139
10	0.270±0.073	2.242±0.022	0.298±0.109	2.176±0.065	0.382±0.085	2.096±0.098	0.505±0.130	1.952±0.169
11	0.288±0.076	2.235±0.025	0.317±0.116	2.156±0.077	0.412±0.092	2.057±0.119	0.539±0.128	1.877±0.198
12	0.307±0.079	2.228±0.027	0.333±0.121	2.133±0.091	0.442±0.099	2.012±0.142	0.576±0.125	1.791±0.227
13	0.326±0.081	2.220±0.030	0.351±0.125	2.108±0.106	0.476±0.104	1.961±0.166	0.608±0.114	1.700±0.248
14	0.346±0.083	2.212±0.034	0.369±0.126	2.081±0.122	0.508±0.108	1.905±0.191	0.642±0.108	1.602±0.263
15	0.366±0.086	2.204±0.037	0.388±0.128	2.051±0.139	0.539±0.106	1.843±0.214	0.658±0.096	1.508±0.261
16	0.387±0.088	2.195±0.041	0.407±0.129	2.018±0.157	0.574±0.106	1.776±0.235	0.683±0.088	1.421±0.247
17	0.408±0.088	2.186±0.045	0.429±0.133	1.983±0.175	0.602±0.105	1.706±0.254	0.676±0.126	1.393±0.281
18	0.427±0.088	2.176±0.049	0.450±0.134	1.945±0.193	0.629±0.105	1.631±0.271	0.700±0.109	1.358±0.398
19	0.446±0.087	2.166±0.053	0.472±0.132	1.904±0.210	0.652±0.103	1.556±0.283	0.702±0.097	1.257±0.328
20	0.464±0.086	2.156±0.058	0.495±0.131	1.860±0.227	0.673±0.102	1.480±0.292	0.693±0.088	1.188±0.195

表 6　Median・IID における malicious ratio 別の Round-Accuracy と Round-Loss（各条件 20 trial の平均 ± 標準偏差）

	Ratio 0.0		Ratio 0.1		Ratio 0.2		Ratio 0.3	
Round	Acc.	Loss	Acc.	Loss	Acc.	Loss	Acc.	Loss
0	0.102±0.034	2.307±0.006	0.099±0.037	2.307±0.011	0.091±0.024	2.310±0.006	0.096±0.027	2.309±0.007
1	0.109±0.035	2.301±0.005	0.109±0.034	2.302±0.009	0.099±0.026	2.304±0.006	0.103±0.028	2.305±0.007
2	0.116±0.037	2.295±0.006	0.120±0.033	2.296±0.009	0.108±0.028	2.299±0.006	0.110±0.029	2.300±0.008
3	0.126±0.039	2.289±0.007	0.132±0.033	2.291±0.008	0.119±0.029	2.294±0.006	0.117±0.031	2.296±0.008
4	0.136±0.042	2.284±0.008	0.145±0.035	2.285±0.009	0.131±0.032	2.289±0.006	0.125±0.033	2.291±0.009
5	0.148±0.044	2.278±0.010	0.158±0.036	2.280±0.009	0.144±0.035	2.284±0.007	0.134±0.037	2.287±0.009
6	0.164±0.048	2.273±0.012	0.173±0.039	2.275±0.010	0.159±0.039	2.279±0.008	0.143±0.041	2.283±0.010
7	0.182±0.053	2.267±0.013	0.189±0.042	2.270±0.011	0.175±0.044	2.274±0.009	0.152±0.045	2.279±0.011
8	0.201±0.060	2.262±0.015	0.206±0.045	2.265±0.013	0.191±0.049	2.269±0.010	0.162±0.049	2.275±0.012
9	0.221±0.066	2.256±0.017	0.225±0.049	2.259±0.014	0.208±0.054	2.265±0.011	0.173±0.054	2.270±0.013
10	0.243±0.072	2.251±0.019	0.245±0.054	2.254±0.016	0.226±0.059	2.260±0.012	0.184±0.059	2.266±0.014
11	0.264±0.077	2.245±0.021	0.264±0.060	2.249±0.017	0.243±0.063	2.255±0.013	0.196±0.063	2.262±0.015
12	0.286±0.082	2.240±0.023	0.285±0.066	2.244±0.019	0.259±0.067	2.250±0.015	0.209±0.067	2.258±0.016
13	0.308±0.087	2.234±0.026	0.306±0.071	2.238±0.021	0.277±0.070	2.245±0.016	0.223±0.070	2.254±0.017
14	0.329±0.092	2.228±0.028	0.326±0.076	2.233±0.022	0.295±0.073	2.240±0.017	0.237±0.073	2.250±0.018
15	0.349±0.095	2.222±0.030	0.346±0.080	2.227±0.024	0.313±0.075	2.235±0.018	0.252±0.076	2.245±0.019
16	0.369±0.099	2.216±0.033	0.366±0.083	2.221±0.026	0.331±0.078	2.230±0.020	0.267±0.079	2.241±0.021
17	0.387±0.102	2.210±0.035	0.385±0.084	2.216±0.028	0.349±0.080	2.224±0.021	0.282±0.081	2.237±0.022
18	0.405±0.104	2.203±0.038	0.404±0.086	2.210±0.031	0.366±0.081	2.219±0.023	0.297±0.084	2.232±0.023
19	0.421±0.106	2.196±0.041	0.422±0.088	2.204±0.033	0.383±0.082	2.213±0.024	0.313±0.086	2.228±0.025
20	0.437±0.107	2.189±0.044	0.439±0.090	2.197±0.035	0.398±0.083	2.207±0.026	0.328±0.088	2.223±0.026

表 7　Median・Non-IID における malicious ratio 別の Round-Accuracy と Round-Loss（各条件 20 trial の平均 ± 標準偏差）

	Ratio 0.0		Ratio 0.1		Ratio 0.2		Ratio 0.3	
Round	Acc.	Loss	Acc.	Loss	Acc.	Loss	Acc.	Loss
0	0.101±0.023	2.309±0.008	0.098±0.018	2.309±0.007	0.097±0.025	2.306±0.008	0.105±0.023	2.305±0.009
1	0.106±0.022	2.305±0.008	0.100±0.020	2.307±0.006	0.097±0.024	2.306±0.008	0.099±0.022	2.308±0.009
2	0.112±0.022	2.301±0.007	0.103±0.021	2.305±0.006	0.096±0.023	2.307±0.008	0.094±0.022	2.311±0.009
3	0.119±0.023	2.297±0.007	0.106±0.022	2.303±0.006	0.095±0.023	2.307±0.008	0.090±0.023	2.315±0.009
4	0.127±0.027	2.293±0.007	0.109±0.024	2.301±0.006	0.095±0.023	2.307±0.008	0.086±0.024	2.318±0.010
5	0.135±0.033	2.289±0.007	0.112±0.027	2.299±0.007	0.094±0.023	2.308±0.008	0.083±0.024	2.321±0.010
6	0.144±0.040	2.286±0.007	0.116±0.030	2.297±0.007	0.094±0.023	2.308±0.008	0.080±0.025	2.325±0.010
7	0.154±0.047	2.282±0.008	0.120±0.033	2.295±0.007	0.093±0.022	2.308±0.009	0.078±0.026	2.328±0.011
8	0.164±0.055	2.278±0.009	0.124±0.037	2.293±0.008	0.093±0.023	2.308±0.009	0.075±0.026	2.331±0.011
9	0.173±0.062	2.274±0.010	0.129±0.041	2.291±0.008	0.093±0.023	2.309±0.009	0.073±0.027	2.335±0.012
10	0.183±0.069	2.270±0.010	0.133±0.046	2.290±0.009	0.093±0.023	2.309±0.009	0.071±0.028	2.338±0.012
11	0.192±0.074	2.266±0.011	0.138±0.050	2.288±0.010	0.093±0.024	2.309±0.009	0.068±0.029	2.341±0.013
12	0.201±0.078	2.262±0.012	0.142±0.054	2.286±0.010	0.093±0.024	2.310±0.009	0.066±0.030	2.344±0.013
13	0.210±0.081	2.258±0.013	0.147±0.058	2.284±0.011	0.093±0.024	2.310±0.010	0.064±0.030	2.348±0.014
14	0.220±0.083	2.254±0.014	0.151±0.062	2.282±0.011	0.093±0.024	2.310±0.010	0.062±0.031	2.351±0.014
15	0.230±0.084	2.250±0.016	0.156±0.066	2.280±0.012	0.094±0.024	2.310±0.010	0.060±0.031	2.354±0.014
16	0.240±0.087	2.246±0.017	0.161±0.069	2.278±0.013	0.094±0.024	2.310±0.010	0.058±0.031	2.357±0.015
17	0.250±0.088	2.242±0.018	0.166±0.072	2.276±0.013	0.095±0.023	2.311±0.010	0.057±0.031	2.360±0.015
18	0.261±0.092	2.237±0.019	0.171±0.075	2.274±0.014	0.095±0.023	2.311±0.011	0.055±0.032	2.363±0.016
19	0.273±0.095	2.233±0.021	0.176±0.078	2.272±0.015	0.096±0.023	2.311±0.011	0.055±0.032	2.366±0.016
20	0.284±0.098	2.228±0.022	0.181±0.080	2.270±0.016	0.096±0.023	2.311±0.011	0.053±0.032	2.369±0.016

表 8　Trimmed Mean・IID における malicious ratio 別の Round-Accuracy と Round-Loss（各条件 20 trial の平均 ± 標準偏差）

	Ratio 0.0		Ratio 0.1		Ratio 0.2		Ratio 0.3	
Round	Acc.	Loss	Acc.	Loss	Acc.	Loss	Acc.	Loss
0	0.100±0.041	2.309±0.012	0.105±0.034	2.308±0.009	0.099±0.028	2.308±0.008	0.095±0.029	2.308±0.008
1	0.108±0.045	2.302±0.012	0.118±0.041	2.303±0.009	0.107±0.032	2.304±0.008	0.103±0.030	2.303±0.008
2	0.118±0.048	2.296±0.012	0.132±0.048	2.298±0.009	0.116±0.036	2.300±0.008	0.112±0.032	2.299±0.008
3	0.131±0.051	2.290±0.013	0.147±0.057	2.293±0.010	0.125±0.039	2.295±0.008	0.120±0.035	2.294±0.008
4	0.145±0.054	2.284±0.014	0.163±0.066	2.287±0.011	0.134±0.042	2.291±0.009	0.130±0.039	2.290±0.009
5	0.161±0.057	2.278±0.015	0.179±0.075	2.282±0.012	0.144±0.045	2.287±0.009	0.140±0.043	2.285±0.010
6	0.178±0.060	2.272±0.016	0.194±0.081	2.278±0.012	0.155±0.046	2.283±0.010	0.152±0.049	2.281±0.010
7	0.196±0.062	2.266±0.017	0.210±0.084	2.273±0.014	0.168±0.048	2.279±0.011	0.163±0.054	2.277±0.011
8	0.214±0.065	2.260±0.019	0.224±0.087	2.268±0.015	0.182±0.051	2.275±0.012	0.175±0.060	2.272±0.012
9	0.233±0.068	2.254±0.020	0.239±0.087	2.263±0.016	0.196±0.054	2.271±0.013	0.187±0.065	2.268±0.013
10	0.252±0.072	2.248±0.021	0.254±0.087	2.258±0.017	0.209±0.057	2.267±0.015	0.200±0.071	2.264±0.014
11	0.271±0.075	2.243±0.023	0.269±0.086	2.253±0.018	0.223±0.060	2.263±0.016	0.213±0.077	2.260±0.015
12	0.291±0.078	2.237±0.025	0.285±0.085	2.248±0.020	0.237±0.063	2.259±0.017	0.226±0.082	2.255±0.016
13	0.311±0.080	2.230±0.026	0.301±0.085	2.243±0.021	0.251±0.065	2.255±0.018	0.239±0.088	2.251±0.017
14	0.331±0.082	2.224±0.028	0.318±0.085	2.237±0.022	0.265±0.067	2.250±0.020	0.253±0.093	2.247±0.018
15	0.351±0.083	2.218±0.030	0.334±0.085	2.232±0.024	0.279±0.069	2.246±0.021	0.268±0.097	2.242±0.020
16	0.371±0.083	2.211±0.032	0.351±0.085	2.227±0.025	0.294±0.070	2.242±0.023	0.283±0.101	2.238±0.021
17	0.390±0.082	2.204±0.034	0.366±0.084	2.221±0.027	0.308±0.073	2.238±0.024	0.299±0.104	2.233±0.022
18	0.409±0.082	2.197±0.036	0.382±0.083	2.216±0.029	0.323±0.075	2.233±0.026	0.314±0.107	2.228±0.023
19	0.428±0.081	2.190±0.038	0.398±0.082	2.210±0.031	0.337±0.078	2.229±0.027	0.330±0.109	2.223±0.025
20	0.445±0.080	2.183±0.041	0.413±0.080	2.204±0.032	0.350±0.081	2.224±0.029	0.346±0.110	2.218±0.026

表 9　Trimmed Mean・Non-IID における malicious ratio 別の Round-Accuracy と Round-Loss（各条件 20 trial の平均 ± 標準偏差）

	Ratio 0.0		Ratio 0.1		Ratio 0.2		Ratio 0.3	
Round	Acc.	Loss	Acc.	Loss	Acc.	Loss	Acc.	Loss
0	0.099±0.026	2.308±0.005	0.094±0.019	2.306±0.008	0.099±0.028	2.309±0.009	0.110±0.020	2.306±0.008
1	0.109±0.027	2.303±0.005	0.097±0.019	2.304±0.009	0.098±0.027	2.310±0.009	0.102±0.017	2.311±0.008
2	0.120±0.030	2.297±0.005	0.100±0.018	2.301±0.009	0.097±0.027	2.311±0.009	0.096±0.017	2.315±0.009
3	0.133±0.033	2.292±0.006	0.103±0.019	2.299±0.009	0.096±0.026	2.312±0.009	0.090±0.018	2.320±0.011
4	0.145±0.038	2.286±0.007	0.106±0.019	2.296±0.009	0.096±0.026	2.313±0.009	0.085±0.021	2.324±0.012
5	0.159±0.044	2.280±0.009	0.110±0.021	2.294±0.010	0.095±0.025	2.314±0.010	0.081±0.024	2.329±0.013
6	0.171±0.050	2.274±0.010	0.114±0.023	2.291±0.010	0.094±0.025	2.314±0.010	0.077±0.026	2.334±0.015
7	0.184±0.055	2.269±0.012	0.118±0.025	2.289±0.011	0.093±0.024	2.315±0.010	0.075±0.028	2.339±0.016
8	0.199±0.060	2.262±0.013	0.123±0.028	2.286±0.011	0.093±0.024	2.316±0.010	0.073±0.029	2.344±0.018
9	0.215±0.064	2.256±0.015	0.127±0.032	2.284±0.012	0.092±0.024	2.317±0.010	0.071±0.030	2.348±0.019
10	0.233±0.068	2.250±0.017	0.132±0.036	2.281±0.012	0.092±0.024	2.318±0.011	0.070±0.030	2.353±0.021
11	0.253±0.072	2.243±0.019	0.137±0.040	2.279±0.013	0.091±0.023	2.318±0.011	0.069±0.030	2.358±0.022
12	0.273±0.074	2.236±0.022	0.143±0.045	2.276±0.014	0.091±0.023	2.319±0.011	0.068±0.030	2.363±0.023
13	0.294±0.074	2.229±0.024	0.148±0.049	2.273±0.015	0.091±0.024	2.320±0.011	0.067±0.031	2.368±0.025
14	0.315±0.074	2.222±0.027	0.153±0.053	2.271±0.016	0.091±0.024	2.321±0.011	0.066±0.031	2.373±0.026
15	0.337±0.073	2.214±0.030	0.158±0.057	2.268±0.016	0.091±0.024	2.321±0.012	0.065±0.031	2.377±0.027
16	0.358±0.072	2.206±0.033	0.164±0.062	2.265±0.017	0.091±0.024	2.322±0.012	0.065±0.031	2.382±0.027
17	0.380±0.071	2.198±0.036	0.169±0.066	2.262±0.018	0.090±0.024	2.323±0.012	0.064±0.032	2.387±0.028
18	0.402±0.070	2.189±0.039	0.175±0.070	2.260±0.019	0.090±0.025	2.323±0.012	0.064±0.032	2.392±0.029
19	0.423±0.071	2.180±0.043	0.181±0.072	2.257±0.020	0.090±0.025	2.324±0.012	0.064±0.032	2.396±0.029
20	0.444±0.071	2.170±0.047	0.187±0.074	2.254±0.021	0.090±0.026	2.325±0.012	0.064±0.033	2.401±0.029

表 10　Krum・IID における malicious ratio 別の Round-Accuracy と Round-Loss（各条件 20 trial の平均 ± 標準偏差）

	Ratio 0.0		Ratio 0.1		Ratio 0.2		Ratio 0.3	
Round	Acc.	Loss	Acc.	Loss	Acc.	Loss	Acc.	Loss
0	0.101±0.027	2.309±0.005	0.108±0.031	2.307±0.009	0.100±0.017	2.306±0.007	0.099±0.026	2.308±0.006
1	0.111±0.030	2.304±0.005	0.116±0.031	2.302±0.008	0.107±0.020	2.302±0.007	0.104±0.027	2.304±0.006
2	0.122±0.034	2.298±0.006	0.126±0.033	2.298±0.007	0.113±0.024	2.297±0.007	0.110±0.029	2.300±0.006
3	0.133±0.040	2.292±0.007	0.136±0.036	2.294±0.007	0.121±0.028	2.293±0.007	0.116±0.031	2.297±0.006
4	0.146±0.047	2.287±0.009	0.146±0.040	2.290±0.007	0.130±0.032	2.289±0.007	0.122±0.033	2.293±0.006
5	0.160±0.053	2.281±0.010	0.157±0.046	2.286±0.008	0.141±0.038	2.285±0.008	0.130±0.036	2.290±0.007
6	0.174±0.059	2.275±0.012	0.169±0.052	2.282±0.009	0.151±0.043	2.281±0.009	0.138±0.040	2.286±0.007
7	0.189±0.061	2.270±0.013	0.182±0.058	2.277±0.010	0.163±0.048	2.277±0.010	0.147±0.043	2.283±0.008
8	0.205±0.065	2.264±0.015	0.195±0.065	2.273±0.011	0.175±0.051	2.273±0.011	0.157±0.047	2.279±0.009
9	0.223±0.067	2.259±0.017	0.208±0.071	2.269±0.013	0.187±0.055	2.269±0.012	0.167±0.051	2.276±0.009
10	0.242±0.070	2.253±0.018	0.221±0.077	2.265±0.014	0.198±0.058	2.265±0.014	0.177±0.054	2.273±0.010
11	0.260±0.075	2.248±0.020	0.234±0.083	2.261±0.016	0.210±0.061	2.261±0.015	0.188±0.058	2.269±0.011
12	0.279±0.079	2.242±0.022	0.248±0.088	2.257±0.017	0.222±0.063	2.257±0.016	0.199±0.061	2.266±0.011
13	0.296±0.083	2.236±0.024	0.262±0.093	2.253±0.019	0.234±0.065	2.253±0.017	0.209±0.063	2.263±0.012
14	0.312±0.086	2.231±0.026	0.276±0.097	2.249±0.021	0.247±0.068	2.248±0.019	0.220±0.065	2.259±0.013
15	0.328±0.089	2.225±0.028	0.290±0.100	2.245±0.023	0.260±0.070	2.244±0.020	0.231±0.067	2.256±0.014
16	0.342±0.090	2.218±0.031	0.304±0.103	2.241±0.024	0.274±0.073	2.240±0.022	0.242±0.069	2.253±0.015
17	0.359±0.092	2.212±0.033	0.318±0.105	2.236±0.026	0.288±0.075	2.235±0.023	0.253±0.071	2.249±0.016
18	0.373±0.091	2.206±0.036	0.332±0.106	2.232±0.028	0.302±0.078	2.231±0.025	0.264±0.072	2.246±0.017
19	0.387±0.091	2.199±0.039	0.345±0.105	2.227±0.031	0.317±0.081	2.226±0.027	0.276±0.074	2.242±0.018
20	0.400±0.089	2.192±0.042	0.359±0.105	2.222±0.033	0.331±0.083	2.222±0.028	0.288±0.075	2.239±0.019

表 11　Krum・Non-IID における malicious ratio 別の Round-Accuracy と Round-Loss（各条件 20 trial の平均 ± 標準偏差）

	Ratio 0.0		Ratio 0.1		Ratio 0.2		Ratio 0.3	
Round	Acc.	Loss	Acc.	Loss	Acc.	Loss	Acc.	Loss
0	0.102±0.029	2.308±0.005	0.105±0.023	2.305±0.007	0.103±0.026	2.305±0.008	0.111±0.028	2.306±0.008
1	0.109±0.024	2.306±0.006	0.096±0.020	2.312±0.007	0.088±0.023	2.315±0.009	0.094±0.026	2.322±0.010
2	0.115±0.030	2.306±0.007	0.087±0.019	2.320±0.008	0.076±0.023	2.326±0.011	0.078±0.025	2.338±0.013
3	0.115±0.025	2.306±0.011	0.079±0.021	2.328±0.009	0.067±0.027	2.336±0.013	0.066±0.027	2.354±0.017
4	0.120±0.035	2.306±0.017	0.072±0.024	2.336±0.011	0.062±0.031	2.347±0.016	0.057±0.029	2.371±0.022
5	0.110±0.019	2.308±0.022	0.065±0.026	2.343±0.013	0.058±0.033	2.358±0.020	0.051±0.031	2.390±0.028
6	0.110±0.026	2.311±0.030	0.060±0.029	2.351±0.015	0.056±0.034	2.369±0.024	0.047±0.033	2.410±0.035
7	0.119±0.033	2.312±0.036	0.055±0.030	2.360±0.017	0.054±0.036	2.381±0.028	0.044±0.033	2.432±0.043
8	0.124±0.031	2.313±0.042	0.051±0.030	2.368±0.020	0.053±0.036	2.393±0.033	0.041±0.033	2.456±0.053
9	0.151±0.047	2.316±0.049	0.047±0.031	2.377±0.022	0.052±0.037	2.407±0.038	0.040±0.033	2.484±0.065
10	0.136±0.039	2.319±0.053	0.044±0.031	2.385±0.025	0.052±0.037	2.421±0.045	0.040±0.033	2.515±0.080
11	0.144±0.040	2.322±0.055	0.042±0.031	2.395±0.028	0.052±0.037	2.436±0.051	0.041±0.033	2.552±0.098
12	0.148±0.050	2.326±0.057	0.040±0.032	2.405±0.031	0.052±0.038	2.452±0.059	0.042±0.034	2.594±0.119
13	0.138±0.042	2.330±0.058	0.038±0.031	2.415±0.035	0.053±0.038	2.469±0.067	0.045±0.036	2.643±0.145
14	0.141±0.045	2.333±0.058	0.037±0.032	2.425±0.038	0.053±0.038	2.488±0.075	0.047±0.037	2.699±0.175
15	0.133±0.042	2.334±0.054	0.037±0.032	2.437±0.043	0.054±0.038	2.508±0.084	0.049±0.038	2.765±0.208
16	0.131±0.042	2.338±0.058	0.036±0.032	2.449±0.048	0.055±0.038	2.529±0.093	0.051±0.038	2.838±0.244
17	0.134±0.046	2.343±0.062	0.036±0.032	2.461±0.053	0.055±0.038	2.551±0.103	0.054±0.037	2.919±0.282
18	0.140±0.051	2.345±0.061	0.036±0.033	2.475±0.058	0.057±0.039	2.576±0.113	0.057±0.036	3.002±0.314
19	0.137±0.047	2.345±0.060	0.036±0.033	2.489±0.064	0.058±0.039	2.601±0.122	0.061±0.036	3.087±0.350
20	0.139±0.052	2.348±0.060	0.036±0.033	2.504±0.070	0.059±0.039	2.628±0.132	0.065±0.036	3.166±0.378

表 12　Bulyan・IID における malicious ratio 別の Round-Accuracy と Round-Loss（各条件 20 trial の平均 ± 標準偏差）．Malicious Ratio 0.3（$f = 30$）はロバスト性条件 $n \geq 4f + 3$（$100 < 123$）を満たさず，実行対象から除外している

	Ratio 0.0		Ratio 0.1		Ratio 0.2	
Round	Acc.	Loss	Acc.	Loss	Acc.	Loss
0	0.108±0.031	2.308±0.007	0.102±0.028	2.305±0.006	0.097±0.027	2.310±0.008
1	0.119±0.031	2.303±0.007	0.111±0.027	2.300±0.006	0.105±0.028	2.304±0.007
2	0.131±0.031	2.297±0.007	0.121±0.028	2.295±0.006	0.114±0.030	2.298±0.008
3	0.144±0.033	2.292±0.008	0.133±0.031	2.290±0.007	0.125±0.033	2.293±0.008
4	0.157±0.035	2.286±0.010	0.147±0.037	2.286±0.008	0.138±0.037	2.288±0.009
5	0.172±0.037	2.281±0.011	0.162±0.045	2.281±0.009	0.152±0.041	2.282±0.010
6	0.189±0.042	2.276±0.013	0.178±0.052	2.276±0.010	0.166±0.047	2.277±0.011
7	0.208±0.047	2.270±0.015	0.195±0.059	2.271±0.011	0.182±0.053	2.272±0.012
8	0.227±0.053	2.265±0.017	0.212±0.066	2.267±0.012	0.199±0.058	2.267±0.014
9	0.248±0.061	2.260±0.019	0.228±0.072	2.262±0.013	0.217±0.063	2.261±0.015
10	0.269±0.069	2.254±0.021	0.244±0.077	2.257±0.015	0.235±0.068	2.256±0.017
11	0.289±0.076	2.249±0.023	0.260±0.082	2.252±0.016	0.254±0.071	2.251±0.018
12	0.309±0.082	2.243±0.025	0.277±0.087	2.247±0.017	0.274±0.074	2.246±0.020
13	0.329±0.087	2.238±0.027	0.293±0.092	2.242±0.019	0.294±0.078	2.240±0.021
14	0.348±0.092	2.232±0.029	0.308±0.096	2.237±0.020	0.315±0.083	2.235±0.023
15	0.367±0.096	2.226±0.032	0.324±0.100	2.232±0.022	0.336±0.089	2.230±0.025
16	0.386±0.099	2.221±0.034	0.340±0.104	2.227±0.023	0.356±0.095	2.224±0.027
17	0.404±0.102	2.214±0.037	0.355±0.108	2.221±0.025	0.375±0.101	2.218±0.029
18	0.421±0.104	2.208±0.040	0.370±0.111	2.215±0.027	0.393±0.105	2.212±0.031
19	0.438±0.105	2.202±0.043	0.385±0.114	2.210±0.029	0.410±0.108	2.206±0.034
20	0.454±0.106	2.195±0.046	0.400±0.116	2.204±0.031	0.426±0.110	2.200±0.036

表 13　Bulyan・Non-IID における malicious ratio 別の Round-Accuracy と Round-Loss（各条件 20 trial の平均 ± 標準偏差）．Malicious Ratio 0.3（$f = 30$）はロバスト性条件 $n \geq 4f + 3$（$100 < 123$）を満たさず，実行対象から除外している

	Ratio 0.0		Ratio 0.1		Ratio 0.2	
Round	Acc.	Loss	Acc.	Loss	Acc.	Loss
0	0.101±0.032	2.305±0.006	0.096±0.017	2.309±0.006	0.102±0.023	2.307±0.008
1	0.109±0.033	2.300±0.006	0.099±0.016	2.305±0.005	0.099±0.022	2.309±0.008
2	0.120±0.035	2.294±0.006	0.101±0.016	2.302±0.005	0.097±0.022	2.310±0.008
3	0.132±0.038	2.289±0.007	0.104±0.016	2.299±0.005	0.094±0.022	2.311±0.009
4	0.146±0.043	2.283±0.008	0.108±0.017	2.295±0.005	0.091±0.022	2.312±0.009
5	0.162±0.051	2.277±0.009	0.112±0.018	2.292±0.006	0.088±0.022	2.314±0.009
6	0.179±0.059	2.271±0.011	0.118±0.021	2.288±0.007	0.086±0.023	2.315±0.009
7	0.198±0.066	2.266±0.012	0.124±0.024	2.285±0.007	0.084±0.024	2.316±0.009
8	0.217±0.073	2.260±0.014	0.131±0.029	2.281±0.008	0.082±0.025	2.318±0.009
9	0.237±0.079	2.253±0.016	0.140±0.034	2.278±0.009	0.080±0.025	2.319±0.009
10	0.257±0.082	2.247±0.018	0.149±0.039	2.275±0.010	0.078±0.026	2.320±0.010
11	0.278±0.085	2.241±0.020	0.159±0.045	2.271±0.011	0.076±0.027	2.322±0.010
12	0.297±0.087	2.234±0.022	0.169±0.050	2.268±0.012	0.075±0.028	2.323±0.010
13	0.317±0.088	2.227±0.024	0.180±0.054	2.264±0.013	0.073±0.028	2.324±0.011
14	0.337±0.088	2.220±0.027	0.191±0.058	2.260±0.014	0.072±0.029	2.326±0.011
15	0.358±0.089	2.212±0.029	0.202±0.062	2.257±0.015	0.072±0.030	2.327±0.011
16	0.378±0.088	2.204±0.032	0.213±0.065	2.253±0.016	0.071±0.031	2.328±0.011
17	0.398±0.088	2.196±0.035	0.224±0.068	2.249±0.017	0.071±0.031	2.330±0.012
18	0.417±0.088	2.188±0.038	0.235±0.070	2.246±0.018	0.071±0.032	2.331±0.012
19	0.437±0.088	2.179±0.041	0.247±0.073	2.242±0.020	0.070±0.032	2.332±0.013
20	0.456±0.088	2.169±0.045	0.258±0.077	2.238±0.021	0.071±0.032	2.334±0.013