Federated Learning における Adaptive Model Poisoning Attack と Robust Aggregation の評価に関する実験計画書

3CDA2216 笠原秀星,3CDA2220 齋藤麻美

2026 年 6 月 24 日

1 研究背景・概要

Federated Learning（以下, FL）は, 生データを共有することなく複数のデバイスや組織が協調して機械学習モデルを学習する分散学習の枠組みである [1]. FL は, ユーザのプライバシー保護と機械学習の両立を可能にする技術として注目されており, スマートフォンにおける単語予測や顔認識, 音声認識技術の向上に利用されている. また, 厳格なプライバシー規制によりデータ共有が困難な医療分野や, 自動運転車におけるリアルタイムデータの活用など, 幅広い分野への応用が期待されている [2].

一方で, FL には収束性, データ分布の不均一性（Non-I.I.D.）, 通信コスト, 大規模環境への適用, モデル集約手法など, さまざまな課題が存在する [3]. 特に, FL では多数の参加者が学習に関与するため, 悪意のあるクライアントによる攻撃への耐性を確保することが重要な研究課題となっている. 医療データや個人情報などの機密性の高いデータを扱う応用が想定されることから, 安全かつ信頼性の高い学習環境の実現が求められている.

FL に対する代表的な攻撃として Poisoning Attack が挙げられる. Poisoning Attack は大きく Data Poisoning Attack と Model Poisoning Attack の 2 種類に分類される. Data Poisoning Attack は学習データそのものを改ざんする攻撃であり, ラベル反転攻撃や Backdoor Attack などが含まれる. 一方, Model Poisoning Attack はクライアントがサーバへ送信するモデル更新や勾配情報を改ざんする攻撃であり, 勾配操作や最適化手法を利用した攻撃などが提案されている.

これらの攻撃に対する防御手法としては, 異常検知, Robust Aggregation, 摂動機構の 3 つに大別される. 異常検知にはコサイン類似度やクラスタリング, スコアベース手法などが用いられる. また, Robust Aggregation には Krum, Trimmed Mean, Median, Bulyan などの集約手法が提案されている. さらに, 摂動機構としては差分プライバシーを利用した手法が広く研究されている [4].

本研究では, これらの中でも Model Poisoning Attack に着目する. Data Poisoning Attack に関してはこれまで多くの研究が行われており, 攻撃に対して頑健な集約手法や検知手法が多数提案されている. 一方で, Model Poisoning Attack は学習データではなくモデル更新そのものを改ざんするため, サーバ側から攻撃を識別することが困難であり, より深刻な脅威となる. また, その防御手法に関する研究は Data Poisoning Attack と比較して十分に進んでいるとは言えない.

さらに, Fang らは Adaptive Model Poisoning Attack を提案し, 既存の Robust Aggregation 手法を考慮した攻撃によって防御機構を回避できる可能性を示している [5]. このことは, 従来の防御手法が必ずしも十分な耐性を有していないことを示唆しており, Adaptive Model Poisoning Attack に対する詳細な評価が必要である.

そこで本研究では, IID 環境および Non-IID 環境において Adaptive Model Poisoning Attack が FL の学習性能に与える影響を評価する. また, Krum や Trimmed Mean などの Robust Aggregation 手法に対する攻撃の有効性を比較・分析し, 既存防御手法の限界を明らかにする. さらに, 攻撃が成立する要因について考察するとともに, Model Poisoning Attack に対する効果的な防御手法について検討することを目的とする.

2 事前知識

2.1 Federated Learning

先に述べたように Federated Learning は生データを共有することなく複数のデバイスや組織が協調して機械学習モデルを学習する分散学習の枠組みである [1]. 集約アルゴリズムとして Federated Averaging (以下,FedAvg) を用いる.FedAvg は Google が 2016 年に発表した論文の中で示されたものである [6].

2.1.1 FedAvg

アルゴリズム 1 に FedAvg の処理手順を示す。

表 1　FedAvg で用いる主な記号

記号	意味
K	全クライアント数
C	各ラウンドで参加する割合
S_t	ラウンド t で選択されたクライアント集合
w_t	グローバルモデル
w_{t+1}^k	クライアント k が更新したモデル
n_k	クライアント k のデータ数
E	ローカル学習のエポック数
B	ミニバッチサイズ
η	学習率

Algorithm 1 Federated Averaging (FedAvg)

Server executes:
Initialize w_0
for each round $t = 1, 2, \dots$ **do**
  $m \leftarrow \max(C \cdot K, 1)$
  $S_t \leftarrow$ random set of m clients
  for all $k \in S_t$ in parallel **do**
    $w_{t+1}^k \leftarrow \text{ClientUpdate}(k, w_t)$
  end for
  $w_{t+1} \leftarrow \sum_{k \in S_t} \frac{n_k}{n_t} w_{t+1}^k$
end for

ClientUpdate(k, w)
Split P_k into batches of size B
for $i = 1$ to E **do**
  for batch $b \in B$ **do**
    $w \leftarrow w - \eta \nabla \ell(w; b)$
  end for
end for
return w to server

まず，サーバはグローバルモデル w_0 を初期化する。その後，各通信ラウンド t において，全クライアント数 K のうち割合 C に応じた m 個のクライアントをランダムに選択する。選択されたクライアント集合を S_t とする。

選択された各クライアントは，サーバから受け取ったグローバルモデル w_t を用いてローカル学習を実施する。各クライアントは自身が保有するデータ集合 P_k をミニバッチサイズ B ごとに分割し，エポック数 E 回の学習を行う。モデル更新には確率的勾配降下法（SGD）を用い，学習率を η とすると，各ミニバッチ b に対して次式によりパラメータを更新する。

$$w \leftarrow w - \eta \nabla \ell(w; b) \tag{1}$$

ここで，$\ell(w; b)$ はミニバッチ b に対する損失関数であり，$\nabla \ell(w; b)$ はその勾配を表す。

ローカル学習終了後，各クライアントは更新後のモデル w_{t+1}^k をサーバへ送信する。サーバは受信したモデルを，各クライアントの保有データ数 n_k に応じて重み付け平均することで新たなグローバルモデル w_{t+1} を生成する。

$$w_{t+1} = \sum_{k \in S_t} \frac{n_k}{n_t} w_{t+1}^k \tag{2}$$

ただし，

$$n_t = \sum_{k \in S_t} n_k \tag{3}$$

である。この処理を複数ラウンド繰り返すことで，生データを共有することなくグローバルモデルを学習する。

2.2　Data Poisoning Attack

Data Poisoning Attack は，攻撃者が学習データそのものを改ざんし，グローバルモデルの性能低下や誤動作を引き起こす攻撃である。Federated Learning では，各クライアントが保有するローカルデータや学習過程をサーバが直接確認できないため，悪意のあるクライアントが改ざんしたデータを用いて学習を行うことで，モデルに悪影響を与えることが可能である [4]。

Data Poisoning Attack は，Label Flipping Attack，Poisoning Sample Attack，Backdoor Attack などに分類される。Label Flipping Attack は，学習データのラベルを意図的に別のラベルへ変更する攻撃である。例えば，数字認識タスクにおいて「1」のラベルを「7」に変更して学習させることで，モデルの分類性能を低下させることができる。

Poisoning Sample Attack は，学習データそのものを改ざんする攻撃であり，ノイズの付加や特定のパターンの埋め込みなどによって学習結果を操作する。

一方，Backdoor Attack は，特定のトリガを含む入力に対してのみ誤分類を引き起こす攻撃である。攻撃者はトリガ付きデータを学習データへ混入させることで，通常の入力に対する性能を維持したまま，トリガを含む入力に対してのみ攻撃者が指定したラベルを出力するようモデルを誘導する。そのため，Backdoor Attack は高い攻撃成功率とステルス性を有しており，発見が困難であるという特徴を持つ。

Data Poisoning Attack は実装が比較的容易である一方，異常なデータ分布やラベルの偏りを利用した検知手法によって防御できる場合がある。そのため近年では，学習データではなくモデル更新そのものを改ざんする Model Poisoning Attack に関する研究が盛んに行われている [4][7][8]。

2.3 Model Poisoning Attack

Model Poisoning Attack は，悪意のあるクライアントがサーバへ送信するモデル更新や勾配情報を改ざんし，グローバルモデルの性能低下や誤動作を引き起こす攻撃である。Data Poisoning Attack が学習データそのものを改ざんするのに対し，Model Poisoning Attack は学習後のモデルパラメータを直接操作する点に特徴がある。そのため，サーバ側から攻撃の有無を判断することが困難であり，Federated Learning における深刻な脅威の一つとして注目されている [4]。

Model Poisoning Attack は, Gradient Manipulation, Optimization Methods，Untargeted Attack の 3 種類に分類される [4]。Gradient Manipulation は，モデル更新の勾配を意図的に操作する攻撃であり，勾配反転（Sign Flipping Attack）やランダムな勾配の挿入などが代表例として知られている。これらの攻撃は，グローバルモデルの収束を妨害し，性能を低下させることを目的とする。

Optimization Methods は，攻撃効果を最大化するようにモデル更新を最適化する攻撃である。攻撃者は正常なモデル更新との差を小さく保ちながら，攻撃目的を達成するようにモデルを改ざんすることで，異常検知や防御機構による検出を回避する。Backdoor Attack や Model Replacement Attack の多くはこの分類に含まれる。

Untargeted Attack は，特定の入力に対する誤分類ではなく，グローバルモデル全体の性能低下を目的とする攻撃である。攻撃者はモデル更新を大きく改ざんすることで，学習の収束を妨害し，モデルの可用性を低下させる。

2.4 Robust Aggregation

Robust Aggregation は，悪意のあるクライアントによる異常なモデル更新の影響を軽減することを目的とした集約手法である [4]。従来の FedAvg では，各クライアントから送信されたモデル更新を重み付き平均によって集約するため，悪意のあるクライアントが極端なモデル更新を送信した場合，グローバルモデルが大きな影響を受ける可能性がある。

この問題に対処するため，Byzantine Fault Tolerance の考え方を取り入れた Robust Aggregation が提案されている。代表的な手法として Mean（FedAvg), Median, Trimmed Mean，Krum，Bulyan などが知られており，異常なモデル更新を除外または影響を低減しながらグローバルモデルを更新する。

2.4.1 Mean (FedAvg)

FedAvg は，Federated Learning において最も広く利用されている集約手法である。各クライアントから送信されたモデル更新を，保有するデータ数に応じて重み付け平均することで新たなグローバルモデルを生成する。

FedAvg は実装が容易で計算コストも低いという利点を持つ一方，異常なモデル更新の影響を受けやすいという欠点がある。そのため，Model Poisoning Attack に対して脆弱であることが知られている。

2.4.2 Median

Median は，各パラメータについて中央値を採用する集約手法である。平均値ではなく中央値を利用することで，極端に大きな値や小さな値の影響を受けにくくなる。

そのため，悪意のあるクライアントが異常なモデル更新を送信した場合でも，その影響を軽減できる。しかし，多数のクライアントが攻撃に参加している場合には性能が低下する可能性がある。

2.4.3 Trimmed Mean

Trimmed Mean は，各パラメータについて極端に大きい値と小さい値を一定数除外した後に平均を計算する手法である。

この手法は外れ値の影響を低減できるため，単純な平均よりも Model Poisoning Attack に対して頑健である。一方で，正常なクライアントの更新が除外される場合もあり，学習性能が低下する可能性がある。

2.4.4 Krum

Krum は，各クライアントのモデル更新と他のクライアントとの距離を計算し，最も多くのクライアントと類似しているモデル更新を選択する手法である。

平均を取るのではなく，信頼できると判断された単一のモデル更新を採用するため，異常なモデル更新を排除しやすいという特徴を持つ。しかし，クライアント数が増加すると計算コストが大きくなるという課題がある。

2.4.5 Bulyan

Bulyan は，Krum と Trimmed Mean を組み合わせた集約手法である。まず Krum を用いて信頼できるモデル更新を選択し，その後 Trimmed Mean によって集約を行う。

複数の Byzantine 攻撃に対して高い耐性を持つことが報告されているが，計算コストが大きく，クライアン

ト数が多い環境では実行時間が増加するという欠点がある。

本研究では，FedAvg を基準手法とし，Median，Trimmed Mean，Krum および Bulyan を Robust Aggregation として採用する。また，Adaptive Model Poisoning Attack を適用した場合の攻撃成功率やモデル精度の変化を比較し，各集約手法の有効性を評価する。

3 関連研究

Subhash Sagar らは，Federated Learning における Poisoning Attack および防御手法に関する包括的なサーベイを行っている。彼らは攻撃を Data Poisoning Attack と Model Poisoning Attack に分類し，さらに防御手法についても Robust Aggregation や異常検知手法などの観点から体系的に整理している。また，各攻撃手法および防御手法の特徴や課題を比較し，Federated Learning におけるセキュリティ研究の方向性を示している [4].

Minghong Fang らは，Byzantine-robust Federated Learning に対する Local Model Poisoning Attack を提案した。従来の Data Poisoning Attack とは異なり，攻撃者は学習データではなく悪意あるクライアントのモデル更新そのものを操作する。攻撃を最適化問題として定式化することで，Krum，Bulyan，Median，Trimmed Mean といった Byzantine-robust Aggregation 手法に対しても有効な攻撃を実現し，既存の防御手法が十分ではないことを示した [5].

Chulin Xie らは，DBA (Distributed Backdoor Attacks) を提案した。従来の Backdoor Attack では全ての攻撃者が同一のトリガを学習するのに対し，DBA ではグローバルトリガを複数のローカルトリガへ分割し，各悪意あるクライアントへ分散して埋め込む。この手法により，従来手法と比較して高い攻撃成功率とステルス性を実現できることを示した [7].

Eugene Bagdasaryan らは，Model Replacement Attack を提案した。この攻撃では，攻撃者が生成した悪意あるモデル更新を拡大して送信することで，集約後のグローバルモデルへ Backdoor を埋め込むことが可能となる。また，Federated Learning で用いられる Secure Aggregation 環境では各クライアントの更新内容を詳細に観測できないため，異常検知による防御が困難であることを示した [9].

Tuan D. Nguyen らは，Backdoor Attack に対する防御手法である FLAME を提案した。FLAME はモデルクラスタリングによる異常なモデル更新の検出，重みクリッピングによる影響の抑制，およびノイズ付与を組み合わせることで，正常なモデル性能を維持しながら Backdoor の影響を低減できることを示した [8].

これらの研究では，Poisoning Attack および Backdoor Attack の有効性や防御手法について検討されている。しかし，Adaptive Model Poisoning Attack に対する各種 Robust Aggregation 手法の耐性については十分な比較評価が行われていない。そこで本研究では，Median，Trimmed Mean，Krum，Bulyan などの Robust Aggregation 手法を対象として Adaptive Model Poisoning Attack を適用し，IID 環境および Non-IID 環境における防御性能を評価する。

4 実験方法

4.1 実験概要

本研究では，Federated Learning 環境において Adaptive Model Poisoning Attack を実施し，各種 Robust Aggregation 手法の耐性を評価する．

実験では，全 100 クライアントから構成される Federated Learning 環境を構築し，悪性クライアント割合およびデータ分布を変化させながら学習を行う．

また，FedAvg，Median，Trimmed Mean，Krum，Bulyan の 5 種類の集約手法を対象とし，攻撃下におけるモデル性能の変化を比較する．

4.2 データセット

本研究では，画像分類タスクの代表的なデータセットである MNIST を用いる．MNIST は手書き数字画像から構成される 10 クラス分類データセットであり，訓練データ 60,000 件，テストデータ 10,000 件を含む．

データ分布が攻撃および防御性能に与える影響を評価するため，IID 環境および Non-IID 環境の両方で実験を行う．IID 環境では各クライアントへデータを均等に分配する．一方，Non-IID 環境ではクライアントごとに保有ラベルを偏らせることで，不均一なデータ分布を再現する．

4.3 学習モデル

学習モデルには，全結合型 Deep Neural Network（DNN）を用いる．モデル構造は，入力層，128 ノードの全結合層，64 ノードの全結合層，および 10 クラス分類のための出力層から構成される．活性化関数には ReLU を用いる．

本モデルは，ロジスティック回帰より高い表現能力を有しながら，CNN や ResNet と比較して実装および実験管理が容易であるため採用する．

4.4 攻撃設定

攻撃手法には，Fang らが提案した Adaptive Model Poisoning Attack を用いる．

Adaptive Model Poisoning Attack は，従来の Model Poisoning Attack とは異なり，サーバで用いられる集約手法の特性を考慮して悪意あるモデル更新を生成する攻撃である．攻撃者は，グローバルモデルの性能低下を目的としてモデル更新を最適化し，Robust Aggregation による防御を回避しながら攻撃を行う．

本研究では，悪性クライアントが正常なローカル学習を実施した後，学習結果をそのまま送信する代わりに，Adaptive Model Poisoning Attack によって生成した悪意あるモデル更新をサーバへ送信する．

また，攻撃の影響を評価するため，全 100 クライアント中の悪性クライアント数を 0，10，20，30 と変化させる．これに対応する悪性クライアント割合はそれぞれ 0%，10%，20%，30% である．

さらに，IID 環境および Non-IID 環境の両方において実験を実施し，データ分布の違いが攻撃効果に与える影響についても評価する．

4.5 防御設定

防御手法として，Robust Aggregation に分類される FedAvg，Median，Trimmed Mean，Krum，Bulyan を用いる．

FedAvg は全クライアントのモデル更新の平均を用いる集約手法である．Median は各パラメータについて中央値を採用する．Trimmed Mean は極端な値を除外した後に平均を計算する．Krum は他のクライアントとの距離に基づいて信頼できるモデル更新を選択する手法である．Bulyan は Krum による候補選択と Trimmed Mean による集約を組み合わせた手法であり，高い Byzantine 耐性を有することが報告されている．これら 5 手法を比較することで，Adaptive Model Poisoning Attack に対する耐性の違いを評価する．

5 評価方法

5.1 評価指標

評価指標には Accuracy および Loss を用いる．

Accuracy はテストデータに対する分類精度を表す指標であり，学習されたグローバルモデルの性能を評価するために用いる．

Loss は損失関数の値を表す指標であり，学習の収束状況を評価するために用いる．Loss が小さいほどモデルの予測結果と正解ラベルとの差が小さく，学習が適切に進行していることを示す．

実験では，各通信ラウンドにおける Accuracy および Loss の推移を記録する．Adaptive Model Poisoning Attack によって Accuracy が低下し，Loss が増加するほど，攻撃の影響が大きいと判断する．

5.2 比較条件

本研究では，

- 集約手法（FedAvg, Median, Trimmed Mean, Krum, Bulyan）
- 悪性クライアント割合（0%，10%，20%，30%）
- データ分布（IID，Non-IID）

を組み合わせて比較を行う．

実験条件数は

$$5 \times 4 \times 2 = 40$$

条件である。

各条件について 3 回ずつ実験を行うため，

$$40 \times 3 = 120$$

回の実験を実施する。

6 実験環境

実験は Python を用いて実装する．深層学習フレームワークには PyTorch を使用し，Federated Learning の実装には Flower を用いる．

全クライアント数は 100 とし，各通信ラウンドでは全クライアントが学習へ参加する．

通信ラウンド数，ローカルエポック数，バッチサイズ，学習率などのハイパーパラメータは予備実験により決定する．

7 実装計画 (適宜検討する)

7.1 MNIST + DNN 版 task.py

- CIFAR-10 読み込み部分を MNIST に変更
- Normalize を MNIST 用に変更
- Net を CNN から全結合 DNN に変更
- 画像入力を flatten する処理を追加
- IID 分割が動くか確認
- Non-IID 分割が動くか確認
- train/test が正常に動くか確認

7.2 Robust Aggregation

- モデル重みをベクトル化する関数を作る
- ベクトルを state_dict に戻す関数を作る

- FedAvg を自作関数として切り出す
- Median を実装
- Trimmed Mean を実装
- Krum を実装
- Bulyan を実装
- aggregation_type で切り替え可能にする
- 小さいダミー更新で各集約の単体テストをする

7.3 悪性クライアント生成

- malicious_ratio を設定できるようにする
- num_clients から悪性クライアント数を計算する
- seed 固定で malicious_ids を生成する
- 0%, 10%, 20%, 30% で正しく生成されるか確認
- server_app から client_app へ配布する

7.4 攻撃実装

- sign_flip を更新量ベースに修正
- scale 攻撃を更新量ベースに修正
- 正常更新 $\Delta = local - global$ を取得
- 悪性更新 $\Delta_{\text{malicious}}$ を生成
- 送信前に $global + \Delta_{\text{malicious}}$ に戻す
- Adaptive Model Poisoning Attack へ拡張

7.5 CSV 保存

- logs/results.csv を作成
- round ごとに Accuracy/Loss を保存
- aggregation_type を保存
- data_split を保存
- malicious_ratio を保存
- seed を保存
- 最終 Accuracy/Loss を summary.csv に保存

7.6 run_experiments.py

- aggregation 一覧を定義
- malicious_ratio 一覧を定義
- data_split 一覧を定義
- seed 一覧を定義
- 全条件を for 文で回す
- 各実験ごとに出力ディレクトリを分ける
- 失敗した条件を記録する
- 途中再開できるようにする

7.7 可視化

- Accuracy 推移を描画
- Loss 推移を描画
- 最終 Accuracy の棒グラフ
- 最終 Loss の棒グラフ
- IID/Non-IID 比較図
- 集約手法ごとの比較図

参考文献

[1] Priyanka Mary Mammen, “Federated Learning: Opportunities and Challenges,” Proceedings of ACM Conference, 2021.

[2] Tian Li, Anit Kumar Sahu, Ameet Talwalkar, Virginia Smith, “Federated Learning: Challenges, Methods, and Future Directions,” arXiv preprint arXiv:1908.07873, 2019.

[3] Chuan Ma, Jun Li, Ming Ding, Howard H. Yang, Feng Shu, Tony Q. S. Quek, H. Vincent Poor, “On Safeguarding Privacy and Security in the Framework of Federated Learning,” arXiv preprint arXiv:1909.06512, 2020.

[4] Subhash Sagar, Chang-Tsun Li, Seng W. Loke, Jinho Choi, “Poisoning Attacks and Defenses in Federated Learning: A Survey,” IEEE Security & Privacy, 2023.

[5] Minghong Fang, Xiaoyu Cao, Jinyuan Jia, Neil Zhenqiang Gong, “Local Model Poisoning Attacks to Byzantine-Robust Federated Learning,” Proceedings of the 29th USENIX Security Symposium (USENIX Security 2020), pp. 1605–1622, 2020.

[6] H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, Blaise Aguera y Arcas, “Communication-Efficient Learning of Deep Networks from Decentralized Data,” Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS), pp. 1273–1282, 2017.

[7] Chulin Xie, Keli Huang, Pin-Yu Chen, Bo Li, “DBA: Distributed Backdoor Attacks against Federated Learning,” International Conference on Learning Representations (ICLR), 2020.

[8] Tuan D. Nguyen et al., “FLAME: Taming Backdoors in Federated Learning,” 31st USENIX Security Symposium (USENIX Security 2022), pp. 1415–1432, 2022.

[9] Eugene Bagdasaryan, Andreas Veit, Yiqing Hua, Deborah Estrin, Vitaly Shmatikov, “How To

Backdoor Federated Learning," Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics (AISTATS), pp. 2938–2948, 2020.