Federated Learning における悪性更新の検知可能性の評価 — 実験結果報告

— sotsuron_plan2.tex 再スイープ（300 実行）の結果 —

3CDA2216 笠原秀星

2026 年 10 月 15 日

1 本報告の位置づけ

本稿は, 研究計画書 [1]（sotsuron_plan2.tex）の「再スイープ」の節で定めた実験（300 実行, 出力先 experiments_detection_v3）の結果をまとめたものである. 以前の版の本稿は予備スイープ（27 実行）の結果を報告していたが, その後データ分割方式・α の定義・ローカルエポック数・ALIE の z の水準・試行数を改めたため, 数値は直接比較できない. 本稿はすべて再スイープの結果に置き換えた. 計画書に再スイープ前に記した 3 つの予測については, 当たったか外れたかをそのまま報告する（§4）. 卒業論文の結果章・考察章の下書きとして用いることを想定する.

2 実験設定

表 1　実験設定（再スイープ）

項目	値
データセット	MNIST
クライアント数 n	20（毎ラウンド全参加）
通信ラウンド数	50
ローカルエポック数	2
バッチサイズ / 学習率	32 / 0.01（SGD）
集約	FedAvg
データ分割	Hsu ら [3] の Dir($\alpha\pi$). 1 台 1,500 件（うち学習に 1,200 件）
Non-IID 度 α	1000 ($\approx$ IID), 5, 1
攻撃	なし, 符号反転（A1）, ALIE（A2）
ALIE の z	0.385, 0.5, 0.75, 1, 1.25, 1.5, 2, 3
悪性割合 f/n	0.2（$f = 4$）
trial	1–10

実行数は $3\,\alpha \times (\text{なし} + \text{A1} + \text{A2} \times 8\,z) \times 10\,\text{trial} = 300$ であり, 1 実行あたり 50 ラウンド × 4 検知器 = 200 行, 全体で 60,000 行の検知指標を得た. 300 実行すべてが 50 ラウンドまで完了している. 途中で失敗して回し直した実行が 37 件あり, その途中までの行はログに残っているが, 分析では条件ごとに最後の実行だけを用いた.

ログから確認できたのは, 分割方式（dirichlet_equal）, α, z, trial, クライアント数（20）, 悪性クライアント数（攻撃ありで 4, なしで 0）, ラウンド数（50）である. ローカルエポック数・学習率などの学習設定は, 実行時の設定記録（run_config.txt）が手元にないため, ログからは確認できていない. また, ラウンドごとのテスト精度（results.csv）とクライアントごとの検知スコア（detection_updates.csv）も手元にないため, 精度は最終ラウンドの値のみを報告する.

3 結果

3.1 グローバルモデルの精度

表 2 に, 50 ラウンド時点のテスト精度（10 試行の平均 ± 標準偏差）を示す.

表 2　50 ラウンド時点のテスト精度 [%]（10 試行の平均 ± 標準偏差）

攻撃	$\alpha = 1000$	$\alpha = 5$	$\alpha = 1$
なし	98.02 ± 0.11	97.43 ± 0.24	94.30 ± 1.25
A1 符号反転	97.09 ± 0.20	95.03 ± 1.01	76.25 ± 7.84
A2 $z = 1$	98.01 ± 0.10	97.28 ± 0.25	92.63 ± 2.69
A2 $z = 2$	97.96 ± 0.10	97.19 ± 0.26	91.75 ± 2.78
A2 $z = 3$	97.86 ± 0.11	96.97 ± 0.31	89.11 ± 3.28

符号反転は $\alpha = 1$ で精度を約 18 ポイント下げ, 試行間のばらつきも大きい（最低 63.2%）. ALIE は $\alpha \geq 5$ ではどの z でも精度をほとんど下げない（攻撃なしとの差は最大 0.5 ポイント）. $\alpha = 1$ では z とともに精度が下がり, $z = 3$ で攻撃なしより約 5 ポイント低い. $z \leq 1.5$ の差は 2 ポイント以内である.

3.2 ALIE に対する検知性能と z

ALIE では push_ratio が構成上ほぼ z に等しい（計画書の式）. 実測でも, 最終 5 ラウンド平均の push_ratio はどの α でも z の 1.00–1.02 倍であった. そこで ALIE

は z を横軸に評価する．図 1 と表 3 に，最終 5 ラウンド（46–50 ラウンド）の AUC を，trial ごとに平均してから trial 間の平均と標準偏差をとって示す．
検知器ごとの傾向は次のとおりである．

- **D1（ノルム偏差）：** z が小さいとほぼ完全に検知でき，z を上げると低下し，$z = 1.25$ で全 α とも最小（0.09–0.16）となったのち，$z \geq 1.5$ で再び上昇する．$\alpha = 1$ では $z = 0.75$–1.5 の範囲で他の α より低く，試行間のばらつきも大きい．
- **D2（コサイン距離）：** $z \leq 1.5$ では全 α で AUC が 0.00 であった．これは悪性更新が常に最も参照方向に近い（最も正常らしい）と判定されていることを意味し，区別できていないのではなく逆向きに完全に分かれている．$z = 2$ で α による差が大きく（0.83, 0.12, 0.00），$z = 3$ で全 α とも検知に転じる．
- **D3（2 クラスタリング）：** 全条件で 0.92 以上であり，z にも α にもほとんど依存しない．
- **D4（スペクトル残差）：** z が小さいと 0.04–0.16 と逆向きに分かれ，ある z を境に 1.0 近くへ急に切り替わる．切り替わる z は，$\alpha = 1000$ で 0.5–0.75 の間，$\alpha = 5$ と $\alpha = 1$ で 0.75–1 の間にあり，$\alpha = 1$ は $z = 1$ でも 0.81 にとどまる．

3.3 符号反転に対する検知性能と push_ratio

表 4　符号反転に対する最終 5 ラウンドの AUC（10 試行の平均 ± 標準偏差）

α	D1	D2	D3	D4
1000	0.97 ± 0.07	1.00 ± 0.00	1.00 ± 0.00	1.00 ± 0.00
5	0.94 ± 0.04	1.00 ± 0.00	0.99 ± 0.01	0.97 ± 0.05
1	0.88 ± 0.08	1.00 ± 0.00	0.98 ± 0.03	0.85 ± 0.12

表 5　最終 5 ラウンド平均の正常更新の広がりと push_ratio

	攻撃なし		符号反転
α	spread	pc1_ratio	push_ratio
1000	0.143	0.086	1.58
5	0.143	0.122	2.03
1	0.155	0.193	2.55

符号反転は D2・D3 で全 α にわたりほぼ完全に検知でき，D1・D4 は α が小さいほどやや低下する（D4: 1.00 → 0.97 → 0.85）．一方，正常更新の広がり spread は $\alpha = 1000$ から $\alpha = 1$ にかけて約 8% しか増えず，符号反転の push_ratio は α が小さいほど**大きく**なった（1.58 → 2.03 → 2.55）．最終 5 ラウンドでの push_ratio は全試行で 1.44 以上であり，1 を下回る領域は観測されなかった．大きく変わったのは正常更新の広がり方の形であり，第 1 主成分の寄与率 pc1_ratio は 0.086 → 0.122 → 0.193 と約 2.2 倍になった．

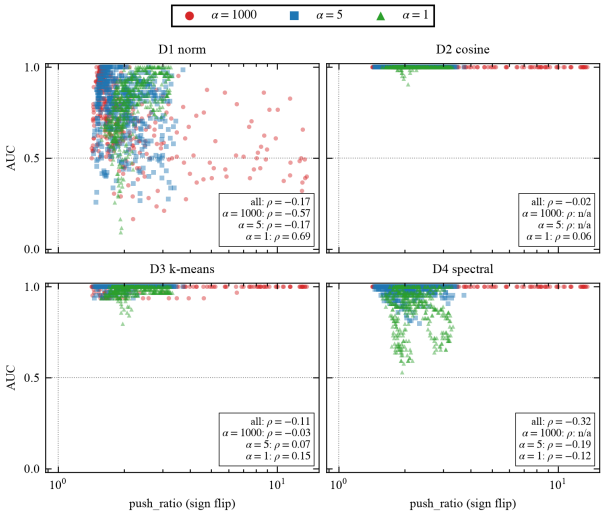


図 2　符号反転における push_ratio（横軸，対数）と AUC（縦軸）．1 点が 1 実行の 1 ラウンド（全ラウンド）．右下は順位相関係数（全体と α ごと．n/a は AUC が一定で計算できないもの）

表 6　符号反転における push_ratio と AUC の順位相関係数（全ラウンド，1 点=1 実行の 1 ラウンド）

α	点数	D1	D2	D3	D4
全体	1,500	−0.17	−0.02	−0.11	−0.32
1000	500	−0.57	n/a	−0.03	n/a
5	500	−0.17	n/a	0.07	−0.19
1	500	0.69	0.06	0.15	−0.12

push_ratio と AUC の順位相関は，全体でも α ごとでも弱いか負であった．例外は $\alpha = 1$ の D1（0.69）のみである．n/a は，その α で AUC がほぼ常に 1.0 であり順位が付けられないことを表す．

3.4 AUC 対ラウンドの推移

図 3 に，検知器（行）と攻撃（列）ごとの AUC のラウンド推移を示す．最終 5 ラウンドの値だけでは見えない点として，次の 3 つがある．

- 符号反転に対する D1 は，序盤の AUC が 0.5 前後で，ラウンドとともに上がっていく．
- ALIE の $z = 1.25$ に対する D1 は，$\alpha = 1000$ では序盤に高く，ラウンドとともに下がる．
- ALIE の $z = 1.5$ に対する D2 は，最初の数ラウンドは高いが，10 ラウンド以内に 0 へ下がる．$z = 2$ でも $\alpha = 5$，1 では同様に下がる．

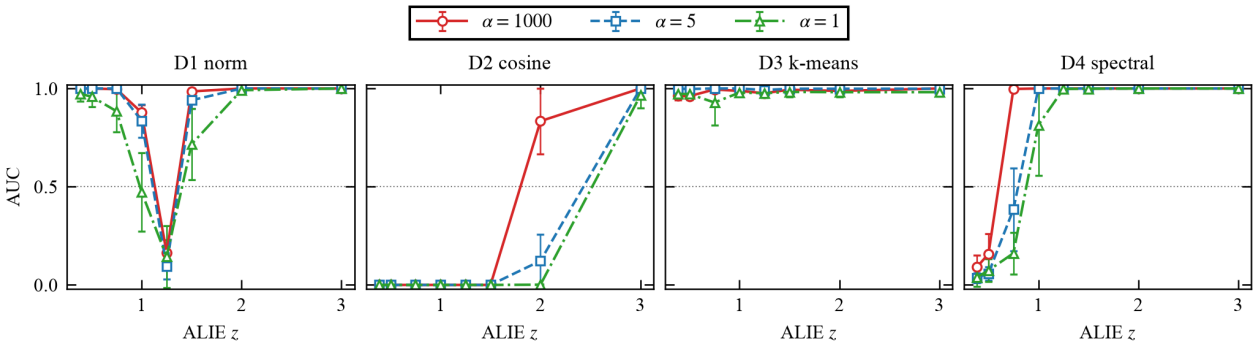


図 1　ALIE の z と最終 5 ラウンドの AUC. 点は 10 試行の平均, 棒は ± 標準偏差. 点線は AUC= 0.5. AUC が 0 に近いのは, 悪性のほうが一貫して正常らしいと判定されていることを表す

表 3　ALIE に対する最終 5 ラウンドの AUC（10 試行の平均 ± 標準偏差）. $z_{\max} \approx 0.385$ は原論文の式で $n = 20$, $f = 4$ から求めた値

	$\alpha = 1000$				$\alpha = 5$				$\alpha = 1$			
z	D1	D2	D3	D4	D1	D2	D3	D4	D1	D2	D3	D4
0.385	1.00	0.00	0.96	0.09	1.00	0.00	1.00	0.04	0.97	0.00	0.97	0.04
0.5	1.00	0.00	0.96	0.16±0.10	1.00	0.00	1.00	0.06	0.96	0.00	0.97	0.07
0.75	1.00	0.00	1.00	1.00	1.00	0.00	1.00	0.39±0.21	0.88±0.11	0.00	0.93±0.12	0.16±0.11
1	0.88	0.00	0.99	1.00	0.84	0.00	1.00	1.00	0.47±0.20	0.00	0.98	0.81±0.26
1.25	0.16	0.00	0.98	1.00	0.09	0.00	0.99	1.00	0.14±0.16	0.00	0.98	1.00
1.5	0.99	0.00	0.99	1.00	0.94	0.00	1.00	1.00	0.72±0.18	0.00	0.98	1.00
2	1.00	0.83±0.17	0.99	1.00	1.00	0.12±0.13	1.00	1.00	0.99	0.00	0.98	1.00
3	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	0.97	0.98	1.00

標準偏差は 0.10 以上のものだけを記した. 数値は `detection_final_auc_table.csv` による.

4　再スイープ前の予測の検証

計画書には, 再スイープの前に次の 3 つの予測を記していた.

予測 1（D1 は z が 1 をやや超える付近で最も低くなり, それより大きい z で再び上昇する）. 当たった. D1 の AUC は全 α で $z = 1.25$ が最小であり, $z = 1.5$ 以上で再び上昇した（表 3）. ALIE の悪性更新 $\mu - z\sigma$ のノルムは, z が小さいと正常更新のノルムより小さく, z を上げるにつれて大きくなる. その途中で正常更新の典型的なノルムと揃う点があり, そこでノルムだけでは区別できなくなると解釈できる. この点が $z = 1.25$ の付近にあることは, 再スイープで初めて分かった.

予測 2（D4 は $\alpha = 1$ でも z を十分大きくすれば検知に転じ, 転じる z は Non-IID が強いほど大きい）. 当たった. D4 は $\alpha = 1$ でも $z \geq 1.25$ で AUC ≥ 0.99 となり, 検知に転じる z は $\alpha = 1000$ で最も小さく（0.5–0.75）, $\alpha = 5$ と $\alpha = 1$ ではそれより大きかった（0.75–1）. ただし $\alpha = 5$ と $\alpha = 1$ の差は, この z の刻みでは区間として区別できず, $\alpha = 1$ が $z = 1$ で 0.81 にとどまる点に表れるのみである.

予測 3（$z \geq 2$ では, FedAvg のもとでも ALIE がグローバルモデルの精度を低下させる可能性がある）. 一部当たった. $\alpha = 1$ では $z = 2$ で約 2.6 ポイント, $z = 3$ で約 5.2 ポイント, 攻撃なしより低下した. 一方 $\alpha \geq 5$ では, $z = 3$ でも低下は 0.5 ポイント以内であった（表 2）.

5　考察

5.1　中心仮説（A1）：本設定では支持されなかった

中心仮説は, Non-IID が正常更新の広がりを増大させ, その結果 push_ratio が下がって検知が難しくなる, というものであった. 再スイープの符号反転では, この連鎖のどちらの段階も観測されなかった. 第一に, データ数を揃えてラベル分布の偏りだけを変えた本設定では, spread は α によってほとんど変わらなかった（約 8%）. 第二に, 符号反転の push_ratio は α が小さいほどむしろ大きくなり, 1 を下回ることはなかった. 第三に, push_ratio と AUC の順位相関は弱いか負であった.

一方で, D1 と D4 の検知性能は α が小さいほど低下しており,「Non-IID が検知を難しくする」こと自体は観測された. その低下は push_ratio の変化では説明できない. 予備スイープで観測された spread の大きな増

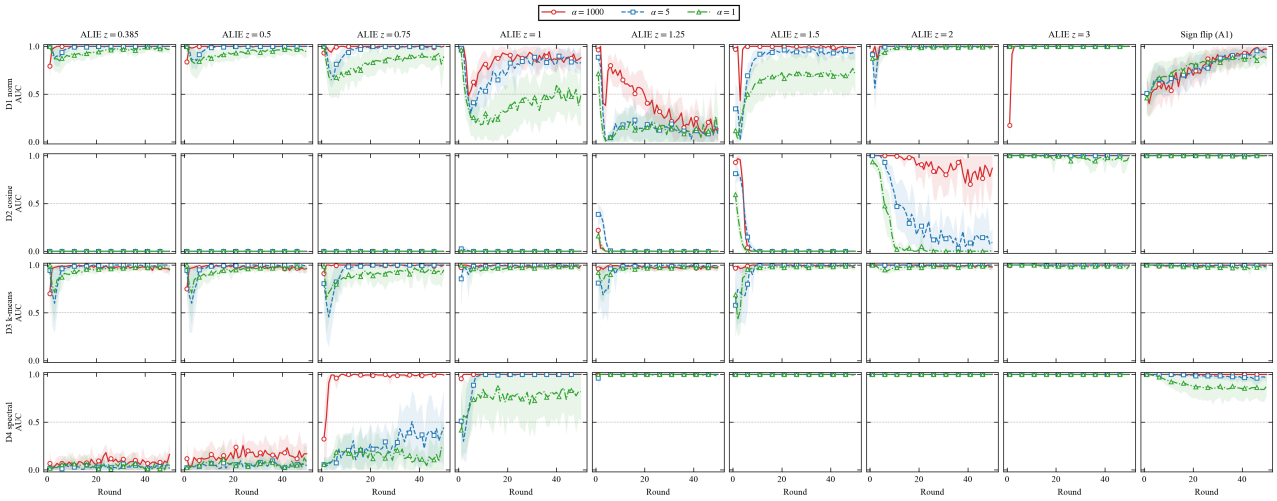


図 3　AUC 対ラウンド．行は検知器 D1–D4, 列は攻撃（ALIE の各 z と符号反転）．線は trial 平均, 帯は ± 標準偏差．赤実線○: $\alpha = 1000$, 青破線□: $\alpha = 5$, 緑一点鎖線△: $\alpha = 1$．点線は AUC= 0.5

加は, データ数の偏りを含む分割方式と異なる学習設定のもとでのものであり, ラベル分布の偏りだけに起因するものではなかった可能性が高い．したがって, A1 についての中心仮説は, 本研究の設定（データ数を揃えたラベル分布の偏り）では支持されなかった, と報告する．

5.2　ALIE: push_ratio では説明できない α の効果

ALIE では push_ratio が z でほぼ決まり, α によって変わらない．それにもかかわらず, 同じ z で α によって AUC が大きく異なった．最も顕著なのは $z = 0.75$ の D4 であり, push_ratio がいずれも約 0.75 であるのに, AUC は $\alpha = 1000$, 5, 1 の順に 1.00, 0.39, 0.16 であった．これは, 検知性能が正常更新の広がりに対する相対距離だけでは決まらないことを示す．

この差と連動していたのは, 正常更新の広がり方の形である．攻撃なし条件の pc1_ratio は $\alpha = 1000$, 5, 1 の順に 0.086, 0.122, 0.193 であり, Non-IID が強いほど正常更新が特定の方向へ細長く広がる．また, 悪性の押し出し方向と全更新の第 1 主成分の重なり mal_cos_pc1_all は, D4 の AUC とよく連動した（ALIE の 24 条件で順位相関 0.92, ラウンド単位で 0.85）．D4 は全更新の第 1 主成分への射影で判定するため, 悪性の押し出しが第 1 主成分になれば検知でき, 正常更新自体の細長い広がりが第 1 主成分を占めていれば検知できない．Non-IID は正常更新の広がりの**大きさ**よりも**形**（異方性）を変え, それが D4 の検知を妨げる, という解釈が考えられる．

ただし, この解釈は結果を見たあとに立てたものである．また, mal_cos_pc1_all は正解ラベルを用いる量であり, D4 の判定方法と直接結びついているため, D4 が失敗する仕組みを言い換えている面がある．独立な検証としては, 符号反転でも同じ関係が成り立つかを確かめる必要がある．符号反転の D4 でも, ラウンド単位で mal_cos_pc1_all との順位相関は 0.75 であった．

5.3　検知器ごとの特徴

D2 の逆向きの分離． D2 は $z \leq 1.5$ の ALIE に対して全 α で AUC 0.00 であった．ALIE の悪性更新は正常更新の平均の近くに作られるため, 座標ごとの中央値を参照方向とするコサイン距離では, 悪性が最も正常らしく見える．AUC が低いことは「区別できない」ではなく「逆向きに完全に区別できる」ことであり, 外れ値を探す検知器にとって「典型的すぎる更新」が死角になることを示している．類似度指標がこの種の攻撃に欺かれやすいことは Wang ら [7] が一般論として指摘しており, 本結果はそれが ALIE に対して具体的に生じることを示す．

D3 が常に高いこと． D3 は全条件で AUC 0.92 以上であった．ALIE では, 原論文のとおり悪性クライアント 4 台が同一のベクトルを送るため, 4 点が互いに距離 0 の固まりになる．D3 の高い性能はこの性質によるものである可能性があり, ALIE の摂動の巧妙さを見破っていることを意味するとは限らない．悪性更新に小さな差をつけた場合の検証は, 本研究の範囲外である．

5.4　精度への影響と検知の関係

$\alpha \geq 5$ では, ALIE はどの z でもモデルの精度をほとんど下げなかった．これは, 防御のない単純平均では攻撃の効果が薄まるという原論文 [2] の報告と整合する．一方, 符号反転は $\alpha = 1$ で精度を約 18 ポイント下げたが, D2 では全試行でほぼ完全に検知できていた．本研究は検知結果を集約に用いていないが, 検知と除外を組み合わせれば精度の低下を防げる余地があることを示唆

する.

6 妥当性への脅威と今後の課題

- **学習設定の確認:** 実行時の設定記録（`run_config.txt`）が手元になく, ローカルエポック数・学習率はログから確認できていない. 実行した計算機の記録で確認する必要がある.
- **精度の推移:** ラウンドごとの精度ログ（`results.csv`）が手元になく, 計画書で併記するとした精度の推移を示せていない. 計画書の事前確認では, $\alpha = 1$ の学習は 50 ラウンドで完全には収束していなかった.
- **ALIE の悪性更新が同一であること:** D3 の高い性能の解釈に影響する. また, 同一の更新を調べるだけで検知できるという点は, この攻撃モデルの限界である.
- **事後の解釈:** §5 の「Non-IID は広がりの形を変える」という解釈は結果を見てから立てたものであり, 別の条件で確かめる必要がある.
- **相関の点の独立性:** 表 6 の順位相関は 1 実行の各ラウンドを 1 点として数えており, 同じ実行のラウンドどうしは独立ではない. 相関の大きさの目安として扱う.
- **回し直した実行:** 37 件の実行が途中で失敗し回し直された. 失敗の原因はログからは分からない.
- **規模と脅威モデル:** 20 クライアント・MNIST・学習データの半分という小規模設定であり, full knowledge・悪性集合固定という前提のもとでの評価である.
- **発展課題（未実施）:** min-max ／ min-sum 攻撃, 悪性割合の拡張, 検知と集約の統合評価は含まれない.

参考文献

[1] 笠原秀星, “Federated Learning における悪性更新の検知可能性の評価に関する研究計画書 — データ分布の不均一性と攻撃のステルス性を軸とした更新ベクトルレベルの評価 —,” `sotsuron_plan2.tex`, 2026.

[2] Gilad Baruch, Moran Baruch, Yoav Goldberg, “A Little Is Enough: Circumventing Defenses For Distributed Learning,” Advances in Neural Information Processing Systems (NeurIPS), 2019.

[3] Tzu-Ming Harry Hsu, Hang Qi, Matthew Brown, “Measuring the Effects of Non-Identical Data Distribution for Federated Visual Classification,” arXiv preprint arXiv:1909.06335, 2019.

[4] Virat Shejwalkar, Amir Houmansadr, “Manipulating the Byzantine: Optimizing Model Poisoning Attacks and Defenses for Federated Learning,” Network and Distributed System Security Symposium (NDSS), 2021.

[5] Brandon Tran, Jerry Li, Aleksander Madry, “Spectral Signatures in Backdoor Attacks,” Advances in Neural Information Processing Systems (NeurIPS), 2018.

[6] Shenghui Li, Edith C.-H. Ngai, Thiemo Voigt, “An Experimental Study of Byzantine-Robust Aggregation Schemes in Federated Learning,” arXiv preprint arXiv:2302.07173, 2023.

[7] Zhilin Wang, Qin Hu, Xukai Zou, “Can We Trust the Similarity Measurement in Federated Learning?,” arXiv preprint arXiv:2311.03369, 2023.